ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК

Файбусович Вячеслав Максимович

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ

Применение моделей машинного обучения для прогнозирования спроса на товары электронной коммерции

Machine Learning Models for E-commerce Demand Forecasting

по направлению 01.04.02 Прикладная математика и информатика
образовательная программа «Аналитика больших данных»

Студент

_____

В. М. Файбусович

Научный руководитель
Старший преподаватель

_____

Н. Н. Титова

Москва 2026

Содержание

1 Введение 3
2 Литературный обзор 5
2.1 Введение в понятие спроса 5
2.2 Восстановление спроса 6
2.3 Категоризация временных рядов 8
2.4 Методы прогнозирования 10
2.4.1 Классические статистические методы 10
2.4.2 Машинное обучение 12
2.4.3 Глубокое обучение 14
2.5 Метрики качества 16
2.6 Валидация, горизонт прогнозирования 18
3 Описание и подготовка набора данных 20
3.1 Загрузка и описание данных 20
3.2 Обработка данных 21
3.3 Восстановление спроса 22
3.4 Категоризация временных рядов 25
4 Построение моделей прогнозирования 27
Список литературы ..... **Ошибка! Закладка не определена.**
Список использованных источников ..... **Ошибка! Закладка не определена.**

1 Введение

В современной глобальной экономике, где доходы от розничной торговли составляют около 31% мирового ВВП, точность планирования становится критическим фактором выживания бизнеса [1]. С развитием цифровой торговли платформы превратились в мощные генераторы данных, что создало условия для перехода от интуитивного управления к предиктивной аналитике. Прогнозирование спроса сегодня — это не просто вспомогательная функция, а фундаментальная основа управления цепочками поставок, напрямую влияющая на финансовую устойчивость предприятия [2, 3].

Основная задача любой модели прогнозирования заключается в поддержании хрупкого баланса между двумя крайностями: избытком запасов (ведет к неоправданно высоким затратам на хранение, замораживанию оборотного капитала и риску порчи или устаревания товаров) и дефицитом запасов (оборачивается упущенной выгодой, снижением уровня клиентского сервиса и долгосрочной потерей лояльности потребителей) [3, 4, 5, 6]. Ошибки в прогнозах порождают «эффект хлыста» (bullwhip effect), когда незначительные колебания потребительского спроса приводят к масштабным сбоям и неэффективности на всех этапах цепочки — от розничной полки до производства [7, 8].

Рыночная среда по своей природе неоднородна, поэтому выбор прогнозного инструментария напрямую определяется спецификой решаемой задачи. Для товарных категорий с устоявшейся историей продаж и предсказуемой динамикой вполне оправдано применение классических статистических моделей, которые дают устойчивый результат при низких трудозатратах [3, 11]. Однако в условиях высокой волатильности, где на спрос одновременно влияют ценовые колебания, маркетинговые акции или внешние факторы вроде погоды, требуются уже более адаптивные методы, способные улавливать нелинейные связи [3, 12]. Отдельную сложность представляет масштаб операций в крупном ритейле: когда счёт товарных позиций идёт на миллионы, построение и поддержка индивидуальной модели для каждого артикула становятся технически нереализуемой задачей, что вынуждает искать компромисс между точностью и вычислительной эффективностью [13, 14].

Эмпирические данные и отраслевой опыт убедительно свидетельствуют о том, что переход к современным прогнозным системам приносит измеримый экономический результат. Внедрение архитектур типа DeepAR от Amazon обеспечивает прирост точности прогнозирования примерно на 15% относительно отраслевых стандартов, а гибридные

решения вроде SARIMA-LSTM позволяют снизить ошибку в среднем на 18% [8, 18, 19. 21]. Применение многозадачных моделей, таких как TFT-MTL, одновременно оценивающих продажи и уровень запасов, сокращает MAPE на 12,7% [20]. Наконец, результаты конкурса M5 Accuracy на данных Walmart демонстрируют улучшение точности более чем на 20% по сравнению с базовыми бенчмарками, что в масштабах крупного ритейлера эквивалентно многомиллионной экономии. [22, 23].

Объектом исследования является спрос на товары, представленные в интернет-магазине. Предмет исследования — совокупность статистических методов, алгоритмов машинного обучения и моделей глубокого обучения, позволяющих прогнозировать спрос на указанные товары.

Цель работы — разработать и верифицировать модель прогнозирования покупательского спроса на ассортимент интернет-магазина, а также оценить её прогностическую способность в сравнении с более простыми (наивными) подходами. Для достижения цели поставлены следующие задачи:

1. Обосновать актуальность выбранной темы, сформулировать объект и предмет исследования, определить цель и перечень решаемых задач.
2. Выполнить аналитический обзор научных и прикладных работ, посвящённых методам прогнозирования спроса в сфере электронной коммерции; систематизировать используемые алгоритмы и критерии оценки качества прогнозов.
3. Сформировать набор исходных данных, провести их предварительную обработку (очистку, восполнение пропусков) и разведочный анализ с построением значимых визуализаций. При необходимости — сконструировать, собрать дополнительные признаки.
4. Сформулировать задачу прогнозирования в терминах регрессии, реализовать несколько альтернативных моделей (статистических, на основе машинного обучения и нейросетевых архитектур) и сопоставить их эффективность по выбранному набору метрик.
5. Определить наиболее результативную модель и проинтерпретировать её работу с точки зрения вклада отдельных факторов и характера допускаемых ошибок.

6. Обсудить практическую применимость полученной модели в работе интернет-магазина и обозначить направления возможных улучшений для повышения точности прогнозирования.

Структура работы выстроена следующим образом. Во введении раскрывается значимость задачи прогнозирования спроса в интернет-торговле, формулируются цель и перечень решаемых в ходе исследования задач. Первая глава содержит обзор научных публикаций и практических работ, посвящённых методам предсказания покупательского спроса в сфере электронной коммерции. Во второй главе представлен используемый набор данных, проведён его разведочный анализ и описаны этапы подготовки к дальнейшему моделированию. Третья глава посвящена методологии построения прогностических моделей — от статистических подходов до алгоритмов машинного и глубокого обучения; здесь же приводятся результаты экспериментов и сравнительная оценка качества полученных решений по заранее определённым метрикам. Четвёртая глава сосредоточена на детальном разборе наиболее успешной модели: интерпретируется вклад отдельных факторов в формирование прогноза и анализируется характер ошибок. Заключительный раздел работы рассматривает вопросы внедрения построенной модели в бизнес-процессы интернет-магазина, намечает направления для дальнейшего совершенствования и подводит итоги выполненного исследования.

2 Литературный обзор

2.1 Введение в понятие спроса

Под спросом в научной литературе понимается латентная переменная, отражающая количество товара, которое потребители готовы приобрести при заданных условиях цены, маркетинга и сервиса в ситуации неограниченной доступности продукта [4, 5]. На его формирование влияют внутренние факторы (цена, промо-акции), внешние условия (активность конкурентов, макроэкономические показатели) и календарные эффекты (сезонность, праздничные дни) [6, 7, 8].

Критически важно понимать, что фактические продажи не эквивалентны истинному спросу [2, 4]. Продажи — это лишь наблюдаемое количество реализованных единиц товара, которое жестко ограничено доступным уровнем складских запасов [4, 5].

Математически зависимость продаж от спроса может быть выражена через следующую формулу:

$$S_t = min(D_t, I_t) \tag{1}$$

где S_t — объем продаж в период;

D_t — истинный спрос в период;

I_t — уровень запасов в период.

Когда спрос превышает запасы ($D_t > I_t$) возникает ситуация дефицита (stock-out), и данные о продажах становятся «цензурированными справа» (right-censored) [10, 11]. В этом случае ритейлер фиксирует реализацию всех имеющихся остатков, но не видит реальный объем неудовлетворенной потребности [11, 12]. Игнорирование этого эффекта при обучении моделей приводит к систематическому занижению прогнозов и возникновению «эффекта нисходящей спирали»: заниженный прогноз ведет к недостаточному пополнению запасов, что провоцирует новый дефицит и еще больше искажает данные [10, 13].

2.2 Восстановление спроса

Процесс восстановления спроса, часто называемый в научной литературе «разограничением» (unconstraining) или «реконструкцией спроса», направлен на оценку того объема продаж, который был бы реализован при отсутствии ограничений на объем товарного запаса [1, 2].

Ниже представлен подробный обзор существующих подходов, условий их применения и эффектов. Методы восстановления спроса принято разделять на четыре основные категории [1, 3]:

1. Базовые методы. К числу простейших методов восстановления спроса относятся прямое наблюдение за неудовлетворёнными запросами (например, регистрация отказов при оформлении заказа), которое считается эталонным, но крайне сложно реализуемо в омниканальной среде, поскольку не учитывает покупателей, покинувших сайт без следа [4]; удаление из выборки периодов дефицита, что сокращает объём данных и способно внести систематическое смещение, если

дефицит возникал не случайно [5]; а также простая импутация — замена нулевых продаж в дни отсутствия товара средним или медианным значением из «здоровых» периодов, которая считается наименее точной и часто лишь усиливает искажения. [6, 7]

2. Статистические методы. Данные методы восстановления спроса опираются на предположение о том, что истинный спрос подчиняется определённому закону распределения — как правило, нормальному, пуассоновскому или отрицательному биномиальному [8, 9]. В рамках этих подходов с помощью математических оценок (например, методов Нахмиаса или Конрада) восстанавливаются параметры соответствующего распределения на основе «усечённой» выборки, содержащей лишь наблюдаемые продажи в периоды отсутствия дефицита [10, 11].
3. Модели выбора. Методы, основанные на моделях выбора, анализируют поведение потребителя в условиях отсутствия желаемого товара: столкнувшись с дефицитом, клиент может либо переключиться на покупку аналогичной позиции (recapture), либо полностью отказаться от приобретения в данной категории (spill) [12, 13]. Использование мультиномиальной логит-модели (MNL) позволяет оценить вероятность такого замещения и на основе этих вероятностей восстановить величину первичного спроса, который изначально был направлен на конкретный товар [7, 14].
4. Алгоритмические методы. К числу оптимизационных методов относится EM-алгоритм (Expectation-Maximization) — наиболее распространённый итеративный подход, на шаге E которого вычисляется ожидаемое значение скрытого спроса, а на шаге M обновляются параметры распределения; однако он показывает слабые результаты на малых выборках [15, 16, 17]. Альтернативой служат методы сглаживания, такие как двойное экспоненциальное сглаживание (DES) или модель с демпфированным трендом (Damped Trend), которые применяются для моделирования динамических трендов и анализа кривых бронирования [18, 19].

Восстановление спроса позволяет разорвать «нисходящую спираль» заниженных прогнозов, при которой недостаточный заказ порождает новый дефицит и ещё сильнее искажает данные, а взамен обеспечивает рост выручки на 2–12% за счёт более точной настройки систем управления доходами [16]. Кроме того, точные методы, например Damped Trend, способствуют снижению ошибок прогнозирования (MAPE) и сокращению затрат на хранение избыточных запасов, что особенно критично в e-grocery и ресторанном бизнесе,

где неверная оценка спроса на скоропортящиеся продукты напрямую ведёт к физическим списаниям и дополнительным убыткам [35, 36, 37, 38].

2.3 Категоризация временных рядов

В отличие от традиционного ритейла, временные ряды в интернет-торговле характеризуются чрезвычайно высокой волатильностью и разреженностью данных, где значительная часть наблюдений представлена нулевыми значениями [2, 3]. Применение универсальных прогностических алгоритмов к таким данным часто ведет к неудовлетворительным результатам, так как методы, эффективные для стабильных продаж, оказываются несостоятельными при работе с прерывистыми паттернами [2, 4].

Научное сообщество признает, что критическим этапом разработки системы прогнозирования является предварительная типизация (категоризация) временных рядов [2]. Она позволяет разделить ассортимент на группы со схожими статистическими характеристиками и назначить для каждой группы наиболее адекватный математический аппарат — от классических статистических методов до глубоких нейронных сетей [5, 6].

Наиболее фундаментальным и широко применяемым подходом в области управления запасами является классификация SBC (Syntetos, Boylan, Croston), предложенная в 2005 году [7, 8]. Она базируется на расчёте двух ключевых параметров временного ряда:

1. ADI (Average Demand Interval): Средний интервал между возникновениями спроса, характеризующий временную регулярность появления заказов, т.е. как часто возникают продажи (спрос).
2. CV^2 (Squared Coefficient of Variation): Квадрат коэффициента вариации объемов спроса, измеряющий изменчивость величины заказа в моменты его возникновения. Показывает регулярность объемов спроса, когда он возникает.

$$ADI = \frac{\sum_{i=1}^{n} t_i}{n}$$

где t_i — интервал между (i-1) и (i) ненулевой продажей, n — количество таких интервалов.

$$CV^2 = \left(\frac{\sigma}{\mu}\right)^2$$

где σ - стандартное отклонение спроса за период (только для ненулевых продаж);

μ - среднее арифметическое спроса за период (только для ненулевых продаж).

На основе пороговых значений (ADI = 1.32 и CV^2 = 0.49), обычно выделяют четыре различных типа паттернов спроса:

1. Гладкий (smooth) спрос. ADI < 1.32 и CV^2 < 0.49. Характеризуется регулярными продажами и низкой вариативностью объема (иначе - низкой дисперсией). Это наиболее предсказуемый тип ряда, он хорошо поддается прогнозированию. Простые скользящие средние, экспоненциальные сглаживания уже показывают удовлетворительные результаты на данном типе временных рядов.
2. Прерывистый (Intermittent) спрос. ADI ≥ 1.32 и CV^2 < 0.49. Продажи происходят редко (есть большие паузы в продажах), но объёмы заказов при этом держатся на примерно одном, относительно стабильном уровне. На этот тип рядов обычно приходится относительно большое количество SKU и достаточно малый оборот.
3. Нерегулярный (Erratic) спрос. ADI < 1.32 и CV^2 ≥ 0.49. Продажи тут идут почти постоянно, без особых остановок, но вот их объёмы при этом чрезвычайно изменчивы — то есть очень сильно гуляют. Часто такое происходит из-за маркетинговых акций или каких-нибудь внешних шоков.
4. Комковатый (Lumpy) спрос. ADI ≥ 1.32 и CV^2 ≥ 0.49. Самый сложный паттерн, сочетающий редкие продажи с огромной вариативностью объемов (иначе – высокой дисперсией). Для него характерна максимальная неопределенность. Является наиболее сложным типом ряда для прогнозирования.

До появления схемы SBC использовались и другие методы, сохраняющие свою актуальность в зависимости от контекста:

1. Метод Уильямса (1984): Основывался на разделении дисперсии спроса за время выполнения заказа на «гладкий», «спорадический» и «медленно меняющийся» типы [11, 18, 19].

2. ABC/XYZ-анализ: Традиционный подход, где товары делятся по вкладу в выручку (ABC) и регулярности потребления (XYZ) [18, 20].
3. VED-анализ: Категоризация товаров по их критичности для процесса (Vital, Essential, Desirable) [18].

Типизация временного ряда служит ключевым «маршрутизатором» при выборе оптимального стека алгоритмов прогнозирования. Для гладких (Smooth) и нерегулярных (Erratic) рядов наиболее эффективны классические модели временных рядов (ARIMA, Prophet) или прямая регрессия на основе градиентного бустинга (LightGBM) с обязательным учётом сезонности и промо-факторов [6, 14]. В случае прерывистого и комковатого спроса классическим выбором остаются метод Кростона и его продвинутые модификации: SBA корректирует положительное смещение, а TSB дополнительно моделирует вероятность возникновения спроса и устойчив к эффекту устаревания товаров [30, 31, 32]. Для работы с крайне нерегулярными данными, где периоды активности «размыты» длинными последовательностями нулей, всё чаще применяются архитектуры глубокого обучения (LSTM, GRU), способные улавливать долгосрочные нелинейные зависимости [30, 34].

Выбор метрик оценки также должен соответствовать типу временного ряда. Традиционные показатели точности (MSE, MAE) на прерывистых данных могут вводить в заблуждение, демонстрируя мнимо хорошие результаты за счёт преобладания нулей. В таких случаях рекомендуется использовать метрики, устойчивые к масштабу и структуре спроса: MASE (обеспечивает сравнение с наивным сезонным прогнозом), SPEC (учитывает затраты на хранение и риски дефицита), а sAPIS измеряет долю времени, в течение которого товар находился в наличии, что критически важно для оценки качества восстановления спроса в периоды сток-аутов.

2.4 Методы прогнозирования

2.4.1 Классические статистические методы

Поскольку покупательская активность в интернет-магазине, а следовательно, и объемы поступающих заказов, крайне неравномерно распределены во времени, задача прогнозирования будущего спроса органично сводится к анализу и моделированию

временных рядов. В электронной коммерции на первом плане находятся предсказание частоты и величины транзакций с учетом множества дополнительных факторов: сезонных всплесков, промо-акций, поведения конкурентов и даже макроэкономических шоков. Существует большое количество подходов к прогнозированию спроса на товары – от базовых статистических методов до сложных нейросетевых архитектур.

Под базовыми статистическими методами в задаче прогнозирования спроса традиционно понимается совокупность подходов, опирающихся исключительно на историю продаж и не требующих привлечения дополнительных внешних данных или сложных алгоритмических конструкций. Такие методы рассматривают временной ряд как реализацию стохастического процесса и строят прогноз, отталкиваясь от выявленных закономерностей — тренда, сезонности и автокорреляционных связей. Несмотря на свою относительную простоту, они формируют фундамент для более сложных моделей и часто служат надёжным «бенчмарком» при оценке эффективности современных решений на основе машинного обучения.

Классический подход к прогнозированию спроса обычно включает в себя такие методы, как:

1. Скользящее среднее. Прогноз на следующий период в данном подходе вычисляется как усреднение значений за несколько предшествующих интервалов. Метод предельно прост в реализации, однако плохо адаптируется к трендовой динамике и сезонным колебаниям, характерным для интернет-продаж.
2. Экспоненциальное сглаживание. Данный метод стал естественным развитием идеи адаптации (подгонки) временного ряда к недавней динамике. Он присваивает более высокие веса недавним наблюдениям. Такие модели хорошо зарекомендовали себя на данных с выраженными сезонными и трендовыми составляющими, что часто встречается в e-commerce при наличии регулярных промо-циклов или годовых сезонностей. Также довольно часто именно экспоненциальное сглаживание может считаться «бенчмарком» для прогнозирования во многих прод-системах.
3. ARIMA. Классическим и мощным инструментом анализа временных рядов остаются модели семейства ARIMA и SARIMA (сезонное расширение ARIMA). Они явно учитывают автокорреляционные зависимости (т.е. обучение происходит на лаговых фичах этого же ряда из прошлого) в данных и способны моделировать регулярные

колебания — дневные, недельные или годовые циклы продаж. В основе этих моделей лежит требование стационарности ряда (или приведение к ней через дифференцирование). ARIMA / SARIMA обеспечивают высокую интерпретируемость результатов, однако их настройка может оказаться нетривиальной, а учёт влияния внешних факторов (например, маркетинговых акций или действий конкурентов) требует перехода к расширениям типа ARIMAX с явным включением экзогенных переменных.

Перечисленные статистические подходы часто выступают в роли «бенчмарков» - базовых эталонов для сравнения с более сложными методами моделирования. Их ключевое преимущество заключается в относительной простоте, прозрачности логики и низких вычислительных затратах. В то же время им часто не хватает гибкости для улавливания сложных нелинейных связей, внезапных изменений спроса или одновременного воздействия множества различных внешних факторов.

2.4.2 Машинное обучение

Традиционные статистические модели, ARIMA (SARIMA) и различные варианты экспоненциального сглаживания - долгое время служили фундаментом прогнозирования спроса благодаря своей математической прозрачности, вычислительной простоте и надёжной работе на относительно стабильных, предсказуемых рядах [2, 3, 4]. Однако в условиях электронной коммерции, характеризующейся нелинейной динамикой, внезапными рыночными сдвигами и сложными взаимозависимостями, такие подходы всё чаще демонстрируют недостаточную гибкость. С развитием вычислительных мощностей и доступности данных на первый план вышли методы машинного обучения (ML) и глубокого обучения (DL), которые, в отличие от классических аналогов, не требуют жёстких априорных предположений о структуре временного ряда и способны автоматически выявлять комплексные нелинейные закономерности. Задачу прогнозирования в этом контексте удобно рассматривать как регрессионную, где целевой переменной (таргетом) выступает ожидаемый объём продаж, а признаками - временные характеристики (час, день недели, месяц), лаговые значения ряда и различные внешние факторы (например - промо-акции, цены, активность конкурентов, объёмы товара на складе, гео-ограничения, затраты на продвижение карточки товара в выдаче). Этот переход позволил компаниям перейти от

реактивного планирования к про-активному управлению запасами на основе данных, что в конечном итоге повышает точность прогнозов, оптимизирует складские остатки и улучшает клиентский опыт за счёт более надёжного исполнения заказов [1, 6].

Современная практика прогнозирования спроса в ритейле опирается на три основных класса алгоритмов машинного обучения:

1. Ансамбли решающих деревьев на основе градиентного бустинга (GBDT), к которым относятся XGBoost, LightGBM и CatBoost [8, 9, 10]. Основная идея этого класса сводится к тому, что каждая следующая итерация модели исправляет ошибки предыдущих. Именно это и позволяет добиваться более высокой точности на разнородных данных электронной коммерции. Самыми важными плюсами этого семейства являются встроенные механизмы регуляризации для борьбы с переобучением (l1, l2 и прочие), эффективная работа с пропущенными значениями, а также оптимизация под большие объёмы данных и категориальные признаки, что делает их незаменимыми, когда нужна сделать прогноз для миллионов товарных позиций.
2. Случайный лес. Данный класс, в отличие от бустинга, строит ансамбль независимых деревьев параллельно, а не последовательно, используя бэггинг плюс случайный отбор признаков. Основное достоинство случайного леса в контексте ритейла - исключительная устойчивость к выбросам и различным аномалиям, столь характерным для транзакционных данных (например, всплески продаж во время хаммеров) [7, 11]. Кроме того, модель предоставляет прозрачную оценку важности предикторов, что позволяет бизнес-пользователям понимать, какие факторы вносят наибольший вклад в прогноз.
3. Ансамблевые и гибридные ML-фреймворки. Такие как стекинг и комбинированные архитектуры (например, RF-XGBoost-LR) [12, 13, 14, 15]. Их суть состоит в агрегации прогнозов нескольких разнородных моделей с помощью мета-алгоритма, что позволяет компенсировать индивидуальные слабости каждого отдельного подхода. Однако основная польза и улучшение модели будет наблюдаться на комбинировании фундаментально разных классов моделей. Основное преимущество и основной выигрыш от комбинирования подходов будут именно в тех случаях, когда модели, которые мы подаем на вход сильно отличаются друг от друга, имеют

разные сильные и слабые стороны. В результате использования ансамблей (гибридов) повышается обобщающая способность системы и стабильность прогнозов.

Если вместо классической статистики применяют методы машинного обучения, то на выходе возникает ощутимый экономический эффект – такой вывод следует из целого ряда эмпирических работ:

1. Переход на AI-ориентированные методы прогнозирования, включая ML, позволяет сократить ошибку на 20–50 % по сравнению с традиционными «бенчмарками» [16].
2. В задачах прогнозирования продаж на маркетплейсах модель XGBoost демонстрирует превосходство над классическими методами, снижая MAPE почти на треть (20–30 %) [17].
3. Применение стекинг-ансамбля из XGBoost, LightGBM и CatBoost позволяет уменьшить RMSE на 16,6 % относительно лучшей одиночной ML-модели (в данном случае — XGBoost) [18].
4. Сложные гибриды, например, комбинация случайного леса и градиентного бустинга с линейным мета-слоем, достигают точности прогнозирования 91 % на недельных данных о продажах [15].
5. В сравнительных тестах на реальных данных розничной торговли наименьшее значение RMSE (4,833) показала именно модель XGBoost, значительно опередив статистические базовые модели [19, 20].

Эволюция, связанная с переходом от статистических моделей к ML (машинному обучению), дала эффект в том, что ограничения из-за жёстких предположений о временных рядах были преодолены, и прогнозирование для электронной коммерции достигло уровня, который раньше был недоступен.

2.4.3 Глубокое обучение

Переход к моделям глубокого обучения (Deep Learning, DL) в электронной коммерции ознаменовал новый этап, позволяющий обрабатывать огромные массивы неструктурированных данных и выявлять сложные временные зависимости без необходимости ручного проектирования (ручной обработки) признаков [1, 2]. В отличие от

классического машинного обучения, нейросетевые архитектуры способны обучаться «сквозным» (end-to-end) способом, напрямую извлекая закономерности непосредственно из самих (сырых) временных рядов [2, 3].

В современных научных работах и «продовых» ритейл решениях выделяется несколько доминирующих архитектур глубокого обучения, каждая из которых решает свои специфические задачи прогнозирования спроса:

1. Рекуррентные нейронные сети (RNN) и их модификации (LSTM, GRU, DeepAR). Основная идея этого семейства заключается в последовательной обработке временного ряда с сохранением внутреннего состояния, что позволяет модели улавливать долгосрочные зависимости. Ключевое преимущество таких архитектур — способность запоминать информацию о далёком прошлом (модель помнит, что происходило год и более назад), что критически важно для учёта сезонности в электронной коммерции [2, 5]. Модели типа DeepAR (создана Amazon), обучаясь одновременно на множестве товарных рядов, дополнительно используют эффект переноса знаний между схожими позициями (SKU), повышая точность прогнозов для товаров с короткой историей или вообще без истории как таковой (новинки) [11, 12].
2. Свёрточные нейронные сети (CNN) и гибриды (ConvLSTM). Изначально разработанные для анализа изображений, CNN в задаче прогнозирования спроса применяются для автоматического выделения локальных паттернов - резких всплесков, падений или характерных форм промо-акций. А когда строят гибридные архитектуры вроде ConvLSTM, то происходит совмещение: свёртки умеют извлекать пространственно-временные признаки, а рекуррентные слои добавляют память. Это как раз и даёт возможность учитывать, как спрос связан между разными регионами или товарными категориями [10]. И за счёт этого получается уже более целостная картина рыночной динамики.
3. Архитектуры на основе механизмов внимания (Transformers). Модели этого класса, в частности Temporal Fusion Transformer (TFT) и Informer делают прогноз таким образом: они смотрят на исторический ряд и с помощью механизма внимания взвешивают, насколько важен каждый конкретный момент. Их главное достоинство - способность одновременно обрабатывать длинные последовательности и сохранять интерпретируемость: например, TFT явно указывает, какие внешние факторы

(промо, цена, активность конкурентов, объёмы товара на складе, гео-ограничения) сыграли наиболее важную роль в каждый момент времени [15, 16]. Это делает их особенно ценными для бизнес-пользователей, которым важна не только точность, но и объяснимость прогноза.

4. Архитектуры разложения базиса (Basis Expansion). Модели семейства N-BEATS и N-HiTS используют глубокие стеки полносвязных блоков для декомпозиции временного ряда на трендовую и сезонную составляющие без привлечения сложных рекуррентных или attention-механизмов. Такие архитектуры демонстрируют выдающуюся вычислительную эффективность (например, N-HiTS работает до 50 раз быстрее трансформеров) и высокую точность на долгосрочных горизонтах, что делает их привлекательным выбором для задач стратегического планирования запасов в ритейле [19, 20].

2.5 Метрики качества

Оценка точности прогнозов лежит в основе принятия решений в управлении цепями поставок, поскольку именно эмпирические данные определяют, какие действия будут предприняты. В условиях электронной коммерции, оперирующей миллионами SKU и крайне волатильным спросом, выбор адекватной метрики превращается из технической детали в стратегический фактор. Неверно подобранный показатель искажает процесс подбора наиболее оптимальной модели, что неизбежно приводит либо к затовариванию складов, либо к дефициту на полке. При этом универсальной метрики, одинаково эффективной для всех типов товаров и горизонтов планирования, не существует.

Метрики качества прогнозов можно разделить на несколько категорий в зависимости от их чувствительности к масштабу данных и устойчивости к выбросам:

1. Абсолютные метрики (MAE, RMSE) измеряют ошибку в натуральных единицах спроса (в штуках) и интуитивно понятны обычным бизнес-пользователям. Их основной недостаток – привязанность к масштабу, что не позволяет сравнивать товары с разным объёмом продаж без предварительной нормализации. RMSE, благодаря квадратичному штрафу за крупные отклонения, становится особенно полезной в ситуациях, когда бизнес боится по-настоящему больших, серьезных

ошибок в прогнозе в ту или иную сторону. Например, провал в прогнозе хаммера (пика распродажи) может нести существенный финансовый и репутационный ущерб. Эффективны для гладкого (Smooth) и хаотичного (Erratic) спроса.

2. Процентные метрики (MAPE, sMAPE) выражают ошибку в относительных величинах. Это теоретически упрощает сравнение между товарами, а также даёт метрику, которая более интерпретируема с точки зрения обычных бизнес-пользователей. Однако их практическое применение в ритейле ограничено: при нулевых или близких к нулю фактических продажах (что типично для прерывистого спроса) MAPE становится невычислимой или даёт бесконечные значения, а симметричная sMAPE не решает эту проблему полностью и может быть смещённой. Эффективны для гладкого (Smooth) и хаотичного (Erratic) спроса.
3. Масштабированные метрики (MASE, RMSSE) стали стандартом де-факто после соревнований M5, так как позволяют сравнивать точность моделей на рядах с любым масштабом и разной степенью прерывистости. В основе подхода лежит масштабирование ошибки модели ошибкой наивного «бенчмарка». Например, MASE показывает, насколько модель лучше или хуже простейшего прогноза «как в прошлом периоде». RMSSE, будучи среднеквадратичной версией, лучше работает с прерывистыми рядами, так как знаменатель рассчитывается только по периодам с ненулевым спросом. Именно эти метрики наиболее адекватно оценивают модели в условиях реального ассортимента электронной коммерции. Достаточно эффективны для прерывистого (Intermittent) и спорадического (Lumpy) спроса.

После того как ошибки прогноза вычислены для каждого временного интервала по каждой товарной позиции, возникает задача их агрегации в сводные показатели, позволяющие оценить качество модели в целом. В ритейл-прогнозировании агрегация обычно проводится на двух уровнях: на уровне отдельного SKU (или комбинации «товар–магазин») и на уровне всей модели, агрегируя индивидуальные метрики по всему набору валидационных рядов. Такой многоуровневый подход позволяет не только получить обобщённую оценку точности, но и выявить возможные систематические искажения — например, склонность модели к завышению или занижению прогнозов (Demand Bias).

2.6 Валидация, горизонт прогнозирования

При оценке качества моделей прогнозирования спроса в ритейле ключевое значение имеет строгое соблюдение временной структуры данных. В отличие от задач классической регрессии, где допустимо случайное перемешивание наблюдений, в работе с временными рядами такой подход приводит к «заглядыванию в будущее» (look-ahead bias) и даёт нереалистично оптимистичные оценки точности. Поэтому во всех исследованиях применяется хронологическое деление выборки с фиксированной точкой отсечения по времени (Рис. 1).

Классическая схема предполагает разделение данных на три непересекающихся интервала: обучающую выборку (например, первые 60% периода) для подгонки параметров модели, валидационную (следующие 20%) для настройки гиперпараметров и отбора признаков, и тестовую (последние 20%), которая остаётся полностью независимой и используется исключительно для финальной оценки обобщающей способности [1, 3]. В некоторых работах, особенно при наличии выраженной годовой сезонности, под тестирование резервируют целый календарный год (например, последние 52 недели), чтобы модель оценивалась на полном сезонном цикле, характерном для электронной коммерции [4].

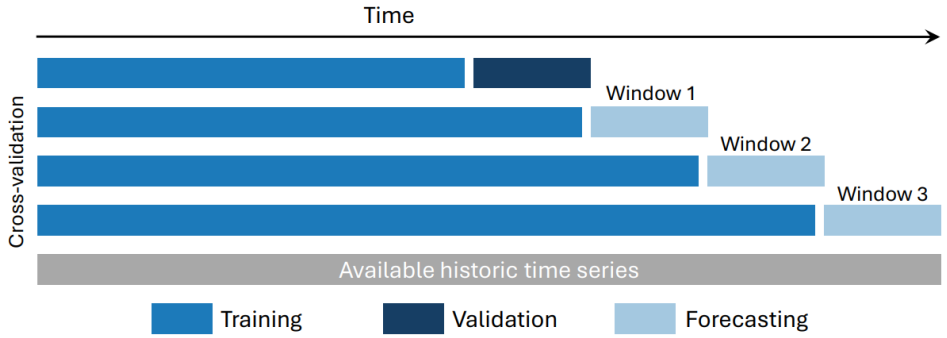

Рис. 1: Пример кросс-валидации с временной структурой данных

Использование традиционной кросс-валидации (K-fold) признается непригодным для временных рядов. Вместо нее используются специфические методы:

1. Walk-Forward Validation (Rolling Origin): «Золотой стандарт», имитирующий реальный процесс прогнозирования: модель обучается на истории, делает прогноз на

шаг h, затем фактическое значение добавляется в историю, и процесс повторяется [2, 6].

2. Expanding Window (Расширяющееся окно): Обучающая выборка прирастает с каждой итерацией. Чем дальше, тем больше данных модель берёт в расчет [7].
3. Sliding Window (Скользящее окно): Размер обучающей выборки жестко фиксирован (например, последние 12 месяцев / 3 квартала / 28 дней). Это лучше подходит для нестационарных сред, где старые данные (например, до пандемии / решения ЦБ) могут быть нерелевантны [7].
4. Blocked Cross-Validation: Использование непрерывных блоков данных без перемешивания, часто с применением «очистки» (purging) и «эмбарго» (embargoing) - удалением данных на границах блоков, чтобы исключить корреляционную утечку информации через лаги [8].

Горизонт прогнозирования - один из важных, ключевых параметров, определяющих как выбор модели, так и практическую ценность её результатов. В ритейле различные бизнес-задачи требуют прогнозов на разных временных интервалах: от оперативного пополнения полки на следующие 14 дней до стратегического планирования закупок на 12 месяцев вперёд. При этом модели часто генерируют прогнозы на дневной детализации, которые затем агрегируются до недельного или месячного уровня для принятия управленческих решений и оценки точности.

Если смотреть с точки зрения тех целей, что стоят перед бизнесом, то обычно выделяют несколько основных горизонтов прогнозирования:

1. Краткосрочный (от 1 до 7 дней) - Для пополнения запасов и логистики «последней мили». Здесь важна максимально возможная точность на каждый день прогнозирования. В некоторых «продовых» системах могут создаваться даже отдельные модели для прогнозирования каждого дня.
2. Среднесрочный (до 4 недель) - типичен для планирования промо-акций, управления ассортиментом и участия в отраслевых соревнованиях (например, классческий конкурс M5 предполагал прогноз как раз-таки на 28 дней). Модели на этом горизонте должны улавливать недельную сезонность и эффекты маркетинговых кампаний.
3. Долгосрочный (от 12 до 26 недель) - Для стратегических закупок, финансового планирования, различных стресс-тестов. При этом модели часто делают ежедневные

прогнозы, которые затем агрегируются в еженедельные (иногда ежемесячные) итоги для оценки точности.

3 Описание и подготовка набора данных

3.1 Загрузка и описание данных

Для проведения исследования был использован набор данных, содержащий детализированную информацию о продажах товаров интернет-магазина, специализирующегося на сегменте автомобильных аксессуаров и сопутствующих категорий. Данные предоставлены внутренней аналитической системой ритейлера, собраны из различных источников и охватывают временной интервал с января 2024 года по сентябрь 2025 года включительно. Общий объём набора данных составляет 10,8 миллионов записей.

Каждая строка датасета представляет собой агрегированные показатели за отдельный календарный день для конкретной товарной позиции (SKU), реализуемой определённым продавцом (SellerID). Наблюдение (строка датасета) отражает дневную динамику по уникальной комбинации «товар — магазин». Набор данных содержит как количественные метрики продаж и остатков, так и справочную информацию о товаре.

Временные атрибуты представлены в двух форматах: поле YYYYMM содержит год и месяц в сжатом числовом виде, а поле Date — полную дату в стандартном формате YYYY-MM-DD, что позволяет выполнять анализ как на уровне месяцев, так и на уровне дней.

Товарная иерархия описывается полями Category3 (категория третьего уровня) и Category4 (категория четвёртого уровня). В анализируемом наборе присутствует только одна категория третьего уровня, связанная с автомобильной тематикой, и четыре подкатегории четвёртого уровня, что позволяет детализировать ассортимент внутри выбранного сегмента. Поле Brand содержит наименование бренда товара — всего в датасете зафиксировано 879 уникальных брендов.

Бинарный признак is_promo указывает на участие товара в промо-акции в конкретный день (1 — товар продвигался по специальным условиям, 0 — стандартная продажа). Поле stock_qty отражает остаток товара на складах, доступный для реализации, по состоянию на начало дня.

Основные метрики продаж представлены тремя показателями. Поле GMV характеризует товарооборот в денежном выражении, рассчитанный по формуле Delivered - Returned, то есть стоимость доставленных заказов за вычетом возвратов. Поле GMV_Acc содержит товарооборот по принятым заказам без вычета возвратов. Количественная мера объёма продаж приведена в поле Items_Acc — количество единиц товара в принятых заказах.

3.2 Обработка данных

В нашем датасете были пропуски только в столбце Brand. Всего таких записей 260. Пропуски в брендах составляют всего 0.000% данных и 0.000% оборота. Было принято решение удалить такие записи из датасета.

В процессе предварительной подготовки данных из анализа были исключены записи, соответствующие уценённым и повреждённым товарным позициям. Это затронуло около 60 тыс. записей. Указанные единицы товара, как правило, представлены в единичных экземплярах и не имеют непрерывной ретроспективной истории продаж, что делает построение временных рядов для них невозможным. Поскольку целью исследования является разработка моделей машинного обучения для прогнозирования регулярного спроса на товары электронной коммерции, включение подобных наблюдений внесло бы существенный шум в обучающую выборку и исказило бы статистические закономерности.

В рамках очистки данных от шумовых наблюдений из рассматриваемой выборки были исключены товарные позиции с аномально низким накопленным оборотом за весь анализируемый период. Критерием отсечения послужило значение суммарного показателя GMV менее 25000 денежных единиц. В результате данной фильтрации из датасета было удалено незначительное с точки зрения общей выручки количество записей, на долю которых приходится лишь 1% совокупного товарооборота. Удаление низкооборотных SKU позволило сконцентрировать анализ на товарах, формирующих основной объём спроса и обладающих достаточной статистической мощностью для построения адекватных прогнозных оценок.

В ходе проверки целостности данных были обнаружены дубликаты, вызванные особенностями хранения транзакций в мастер-системе. Для отдельных товарных позиций SKU_ID зафиксированы конфликтующие значения идентификатора поставщика SupplierID

и продавца SellerID, что противоречит бизнес-логике: один артикул должен быть однозначно связан с единственным поставщиком и продавцом. С целью устранения неопределённости и восстановления целостности для каждого товара были унифицированы атрибуты бренда, поставщика и селлера путём приведения к преобладающему значению.

3.3 Восстановление спроса

Как уже отмечалось ранее, ключевое различие между спросом и фактическими продажами заключается в том, что продажи всегда ограничены имеющимся на складе количеством товара. Если товар заканчивается раньше, чем удовлетворён весь интерес покупателей, мы наблюдаем лишь часть реального спроса — данные обрезаются по верхней границе доступных остатков. Без учёта этого цензурирования модели прогнозирования обучаются на неполной картине и систематически занижают будущие потребности. Восстановление скрытого спроса по усечённым данным продаж становится, таким образом, необходимым этапом для получения адекватных прогнозов и планирования.

Для построения полного временного профиля наличия товаров было сформировано «полотно» из всех возможных комбинаций идентификатора товара SKU_id и календарной даты в пределах анализируемого периода. Для каждой товарной позиции была определена дата её первого появления на складе. Записи, предшествующие моменту первого поступления товара в продажу, были исключены из дальнейшего рассмотрения.

После формирования полного временного профиля остатков был выполнен анализ перерывов в доступности товаров. Для каждого SKU рассчитывались интервалы отсутствия товара на складе, что позволило выявить периоды потенциального дефицита. Всего зафиксировано 95 040 перерывов, медианная длительность которых составила 5 дней, а 90% значений не превышают 31 дня. Распределение перерывов визуализировано на рисунке 2. Полученные характеристики используются в дальнейшем для обнаружения случаев дефицита товаров и настройки процедур его восстановления.

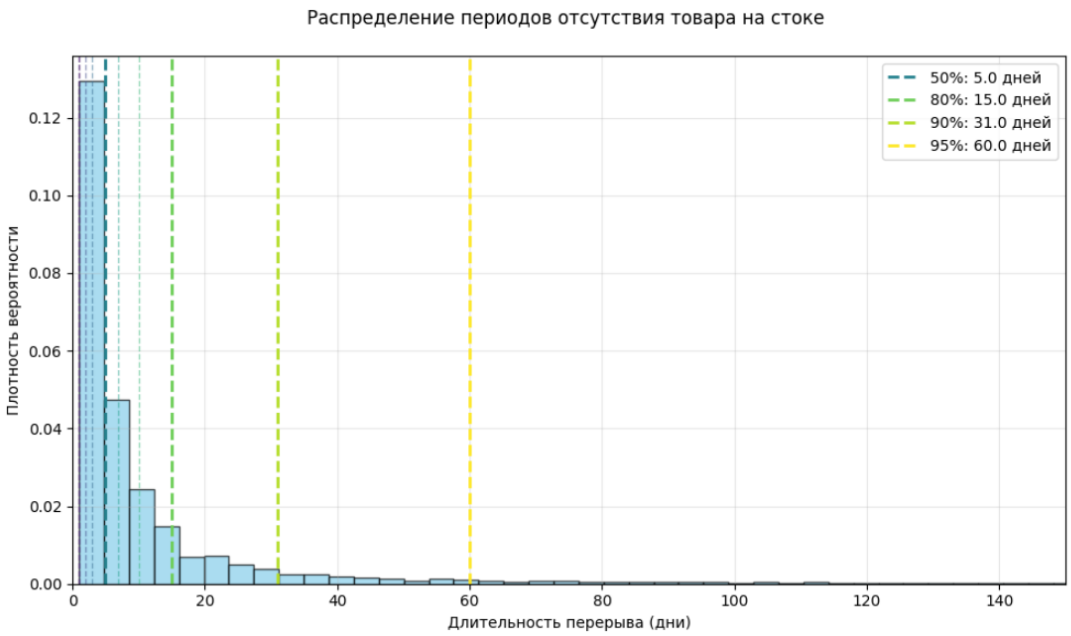

Рис. 2: Распределение длительности периодов отсутствия товарной позиции

Для того чтобы сосредоточиться на товарах, для которых восстановление спроса может быть выполнено с достаточной надёжностью, из выборки были исключены SKU с чрезмерно длительными периодами отсутствия продаж. Я предполагаю, что при очень больших перерывах (например, месяц и более) восстановить реальную картину спроса по имеющимся данным становится затруднительно, а включение таких позиций способно внести существенные искажения в последующие модели. Рисунок 2 демонстрирует, что 90% перерывов имеют длину в 31 день и меньше. Было установлено, что на SKU с максимальным перерывом не более 31 дня приходится около 80 % совокупного оборота. Исходя из всех вышеназванных факторов, в качестве границы был выбран 31 день. Все позиции, у которых максимальный перерыв без стока составил 32 дня и более, были удалены из дальнейшего анализа. Такой подход позволил сконцентрироваться на товарах с достаточно стабильным спросом, сохранив при этом подавляющую часть информативного объёма продаж и одновременно исключив позиции, для которых восстановление спроса было бы сопряжено с высокой неопределённостью.

Для того чтобы впоследствии восстановить неудовлетворённый спрос в периоды отсутствия товара, была выполнена итеративная разметка дней с предполагаемым дефицитом. Для каждого SKU в хронологическом порядке рассчитывалась медиана фактических продаж (Items_Acc) за семь предыдущих дней, в которых дефицит не был зафиксирован; при этом требовалось не менее трёх таких дней. Если текущий складской

остаток оказывался строго ниже этой медианы, день помечался как дефицитный, и его объём продаж не включался в историю для последующих вычислений — это предотвращает попадание в опорное окно дней с продажами, искусственно заниженными из-за отсутствия товара. Полученная бинарная разметка дефицитных дней в дальнейшем служит основой для восстановления спроса в эти периоды.

После разметки дефицитных дней была получена непрерывная оценка типичной интенсивности продаж, не искажённая периодами отсутствия товара. Для каждого SKU на основе только бездефицитных дней вычислялась скользящая медиана продаж шириной 30 дней, которая затем экстраполировалась на следующие за окном дефицитные интервалы. Таким образом, для каждого дня была определена расчётная интенсивность спроса (параметр λ), равная наблюдаемым продажам в дни без дефицита и медианной оценке — в дефицитные. Опираясь на предположение о пуассоновском характере дневного спроса, из распределения Пуассона с параметром λ для каждой даты генерировалась случайная реализация истинного спроса, которая затем корректировалась снизу фактическими продажами (чтобы не занижать известный минимум) и ограничивалась сверху максимальным наблюдённым значением, предотвращая неправдоподобные выбросы. Итоговый восстановленный спрос в бездефицитные дни совпадает с фактическими продажами, а в дни предполагаемого дефицита заменяется сэмплированной величиной. Результат работы алгоритма восстановления спроса для одной из SKU продемонстрирован на рисунке 3.

Рис. 3: Визуализация продаж и восстановленного спроса для одной из SKU

3.4 Категоризация временных рядов

Как уже подчёркивалось ранее, ключевым условием построения надёжной прогнозной системы выступает грамотная предварительная категоризация временных рядов. В интернет-торговле ряды отличаются крайне высокой волатильностью, разреженностью и подавляющей долей нулевых наблюдений, из-за чего универсальные алгоритмы прогнозирования практически неизбежно дают неудовлетворительные результаты. Без осмысленной типизации методы, прекрасно работающие для стабильных продаж, оказываются беспомощными перед прерывистыми паттернами. Именно поэтому научное сообщество рассматривает такую типизацию как первоочередной этап: она позволяет разбить ассортимент на группы со схожими статистическими характеристиками и назначить каждой группе наиболее адекватный математический аппарат — от классических статистических моделей до глубоких нейронных сетей. В настоящей работе для решения этой задачи применяется методология категоризации SBC, предложенная Syntetos, Boylan и Croston в 2005 году [7, 8].

В работе используется разделение временных рядов на пять типов. Для категоризации каждого ряда берутся последние 90 дней наблюдений, а не вся доступная история: такой горизонт позволяет исключить искажающее влияние периода разгона, характерного для новинок, когда стартовое обилие нулевых значений способно ошибочно классифицировать товар, как имеющий прерывистый спрос. Позиции, по которым в этом 90-дневном окне не зафиксировано ни одной продажи, сразу помечаются как retired и исключаются из прогнозирования. Оставшиеся ряды классифицируются по оригинальной схеме Syntetos и Boylan на четыре категории — smooth, erratic, intermittent и lumpy — в зависимости от сочетания среднего интервала между ненулевыми значениями и квадрата коэффициента вариации. Пороговые величины заимствованы из первоисточника (adi_threshold=1.32, cv2_threshold=0.49), однако они не являются догмой и при адаптации к конкретному ассортименту могут быть переопределены.

Распределение рядов по типам продемонстрировано в таблице 1. Как можно увидеть, распределение резко асимметрично: всего 12% SKU типа smooth формируют 55% продаж, тогда как самая многочисленная группа intermittent (54% SKU) приносит лишь 14% продаж. Типы erratic и lumpy совместно занимают около 30% объёма, а retired почти не дают вклада. Такая структура отражает типичный принцип Парето: компания держит широкий «длинный хвост» для охвата ниш, а основной оборот делают немногие стабильные позиции.

Тип ряда	Кол-во рядов	% от общего кол-ва рядов	% от общего оборота в штуках
smooth	1 808	12%	55%
erratic	841	5%	20%
intermittent	8 355	54%	14%
lumpy	3 160	20%	10%
retired	1 307	8%	1%

Таблица 1: Распределение временных рядов по категориям

Как можно увидеть на рисунке 4, четыре типа рядов чётко различаются по сочетанию регулярности продаж и характеру волатильности. Smooth ряды демонстрируют стабильные продажи на определенном уровне с устойчивым разбросом объёмов во времени, формируя относительно предсказуемую картину. Erratic спрос, напротив, сохраняет высокую частоту транзакций, но размер заказа сильно скачет, что видно по широкому разлёту значений на графике. Intermittent тип выделяется большим количеством нулевых промежутков, при этом ненулевые продажи относительно стабильны — на рисунке это выражено в разреженной, но сосредоточенной области вблизи невысоких значений. Lumpy ряды сочетают нулевые продажи с резкими всплесками объёмов, поэтому на визуализации они одновременно и разрежены, и растянуты по широкому диапазону величин.

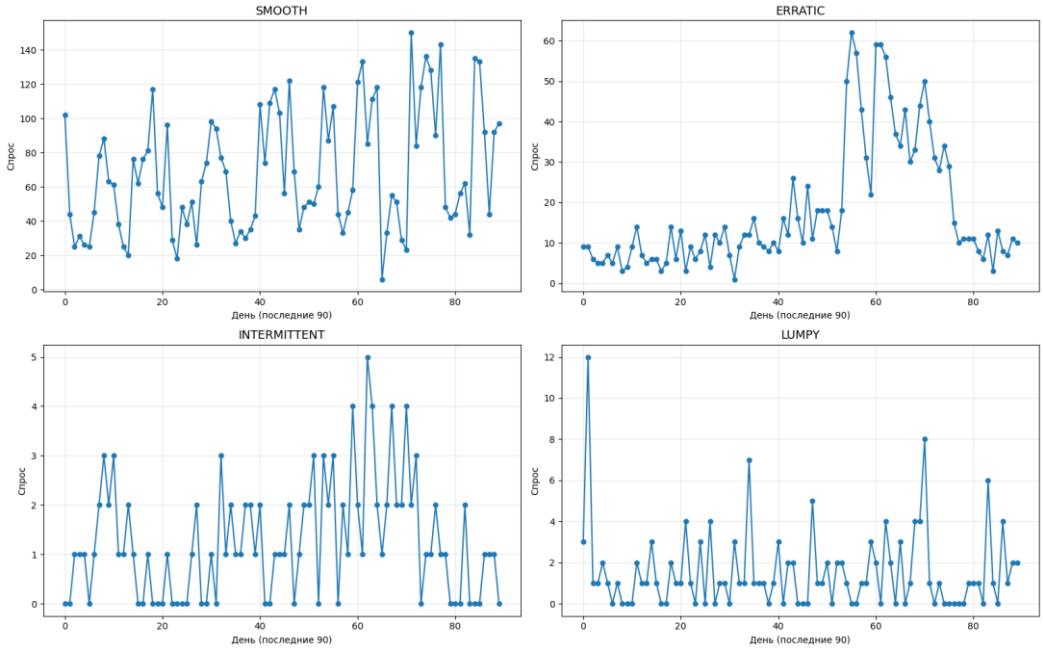

Рис. 4: Визуализация различных категорий рядов на примерах SKU из датасета

4 Построение моделей прогнозирования