Факультет компьютерных наук

Аналитик больших данных

Москва 2026

Применение моделей машинного обучения для прогнозирования спроса на товары электронной коммерции

Студент: Файбусович Вячеслав Максимович
Научный руководитель: Титова Наталия Николаевна

Цель

Построить модели для прогнозирования спроса на товары электронной коммерции

Задачи

1. Подготовка набора данных
2. Восстановление спроса
3. Категоризация временных рядов
4. Построение моделей прогнозирования
5. Анализ результатов

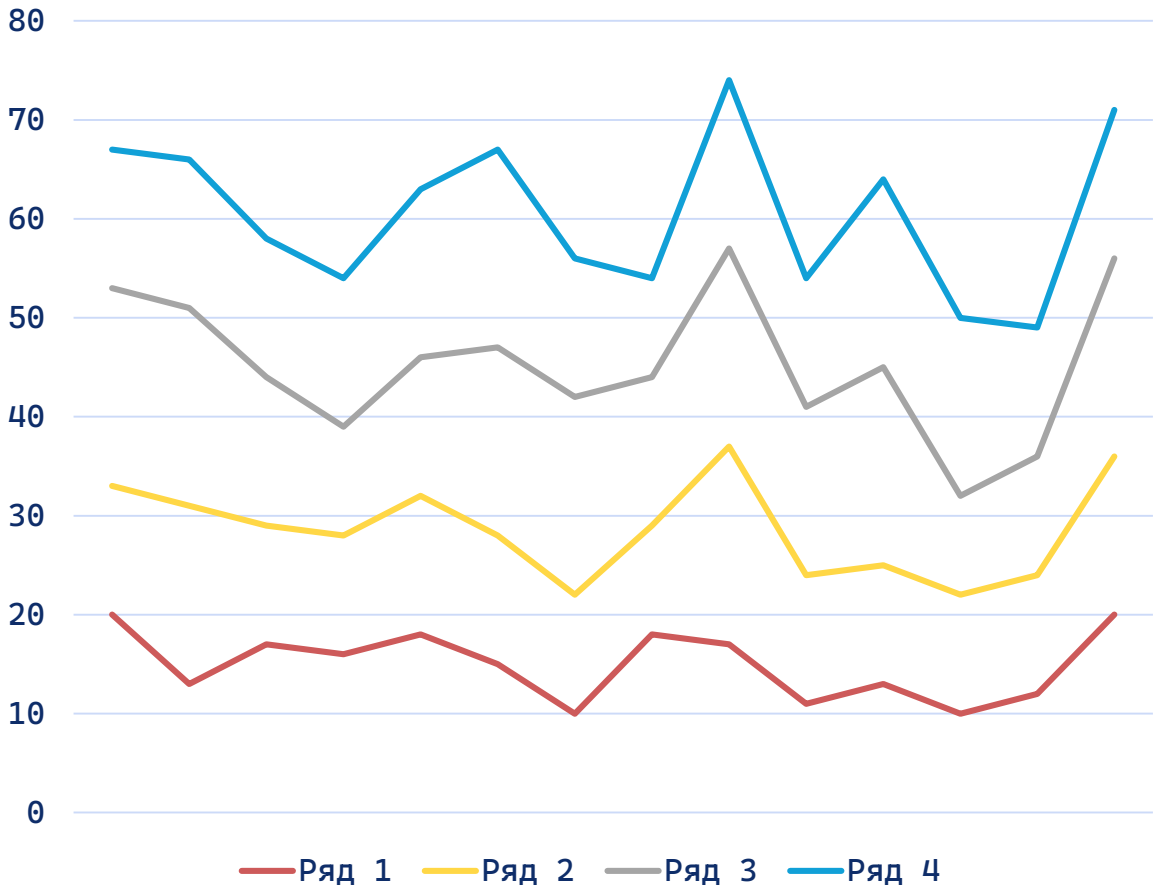

Описание данных

Набор данных содержит информацию о продажах товаров интернет-магазина

10.8 млн записей

Содержит датасет в детализации до уровня подневных продаж каждой SKU

21 месяц наблюдений

Период с января 2024 по сентябрь 2025

4 категории

Весь ассортимент относится к автомобильной тематике

2960 продавцов

Широкий охват производителей различных марок

2 метрики продаж

GMV (товарооборот в денежных единицах) и Items (в штуках товара)

2 доп. признака

Бинарный флаг участия в промо и складские остатки

Поле	Описание	Тип
YYYYMM	Год и месяц в формате `ГГГГММ`	целое число
Date	Дата в формате `YYYY-MM-DD`	дата
Category3	Категория 3-го уровня (одно уникальное значение)	строка
Category4	Категория 4-го уровня (всего 4 категории)	строка
Brand	Бренд товара (879 уникальных брендов)	строка
SupplierID	ID поставщика (2 765 уникальных)	строка / целое
SellerID	ID магазина-продавца (2 960 уникальных)	строка / целое
SKU_ID	ID товара (≈ 91 000 уникальных SKU)	строка / целое
is_promo	Участие товара в промо-акции в данный день	бинарный (0/1)
stock_qty	Доступный остаток товара на складе на начало дня	количество
GMV_wo_VAT	Товарооборот (D–R) без НДС: доставленные заказы за вычетом возвратов	денежные ед.
GMV_wo_VAT_Acc	Товарооборот (Acc) без НДС: только принятые заказы	денежные ед.
Items_Acc	Объём принятых заказов, шт.	количество

Описание исходных данных

Предобработка данных

Обработка пропусков

260 записей с пропуском в столбце Brand были удалены.

Уцененные товары

60 тысяч записей были удалены, т.к. относились к уцененным и поврежденным товарным позициям.

Низкий оборот

Из рассматриваемой выборки были исключены товары с аномально низким оборотом (< 25 тыс. денежных единиц). Это 1% от совокупного товарооборота.

Проверка целостности

У некоторых SKU было несколько значений SupplierID и SellerID. В целях устранения неопределенности для каждого товара были унифицированы атрибуты поставщика и селлера путём приведения к преобладающему значению.

Анализ данных

Месячная сезонность

В данных заметна внутригодовая сезонность. Рост в начале года, стагнация с апреля по июнь, возобновление роста.

Эффект выходного дня

Продажи в субботу и воскресенье в среднем ниже, чем продажи в будние дни.

Расширение ассортимента

Количество уникальных товаров, брендов и селлеров устойчиво растёт на рассматриваемом промежутке времени.

Диспропорция GMV

В данных наблюдается сильная диспропорция в распределении товарооборота. Почти 80% оборота приходится на одну товарную категорию. На самый большой бренд приходится 16% товарооборота.

Понятие спроса

– Наблюдаемые продажи ≠ Спрос

Фактические продажи отражают только реализованную часть спроса, ограниченную доступным остатком товара на складе.

– Цензурирование данных

Если товар заканчивается до удовлетворения всего покупательского интереса, данные продаж обрезаются по верхней границе – мы видим неполную картину (усечённую выборку).

– Риск систематической ошибки

Модели, обученные на таких усечённых данных, систематически занижают прогноз будущего спроса, что влечёт неоптимальное планирование запасов.

– Восстановление как обязательный этап

Чтобы получить адекватный прогноз, необходимо сначала «восстановить» скрытый (неудовлетворённый) спрос – перейти от наблюдаемых продаж к оценке ненаблюдаемого истинного спроса.

«Айсберг» спроса

Восстановление спроса

– Анализ перерывов

В рассматриваемом датасете около 95 тыс. перерывов в доступности товара. Медианная длина перерыва – 5 дней. 90% перерывов не превышают 31 день.

– Длинные перерывы

Позиции с перерывами 32+ дней были исключены из рассмотрения из-за слишком высокой неопределенности при восстановлении спроса.

– Итеративная разметка дефицитных дней

Для каждого SKU в хронологическом порядке считается медиана продаж за 7 предыдущих бездефицитных дней. Если текущий остаток товара на складе строго ниже этой медианы, день помечается как дефицитный.

Алгоритм восстановления спроса

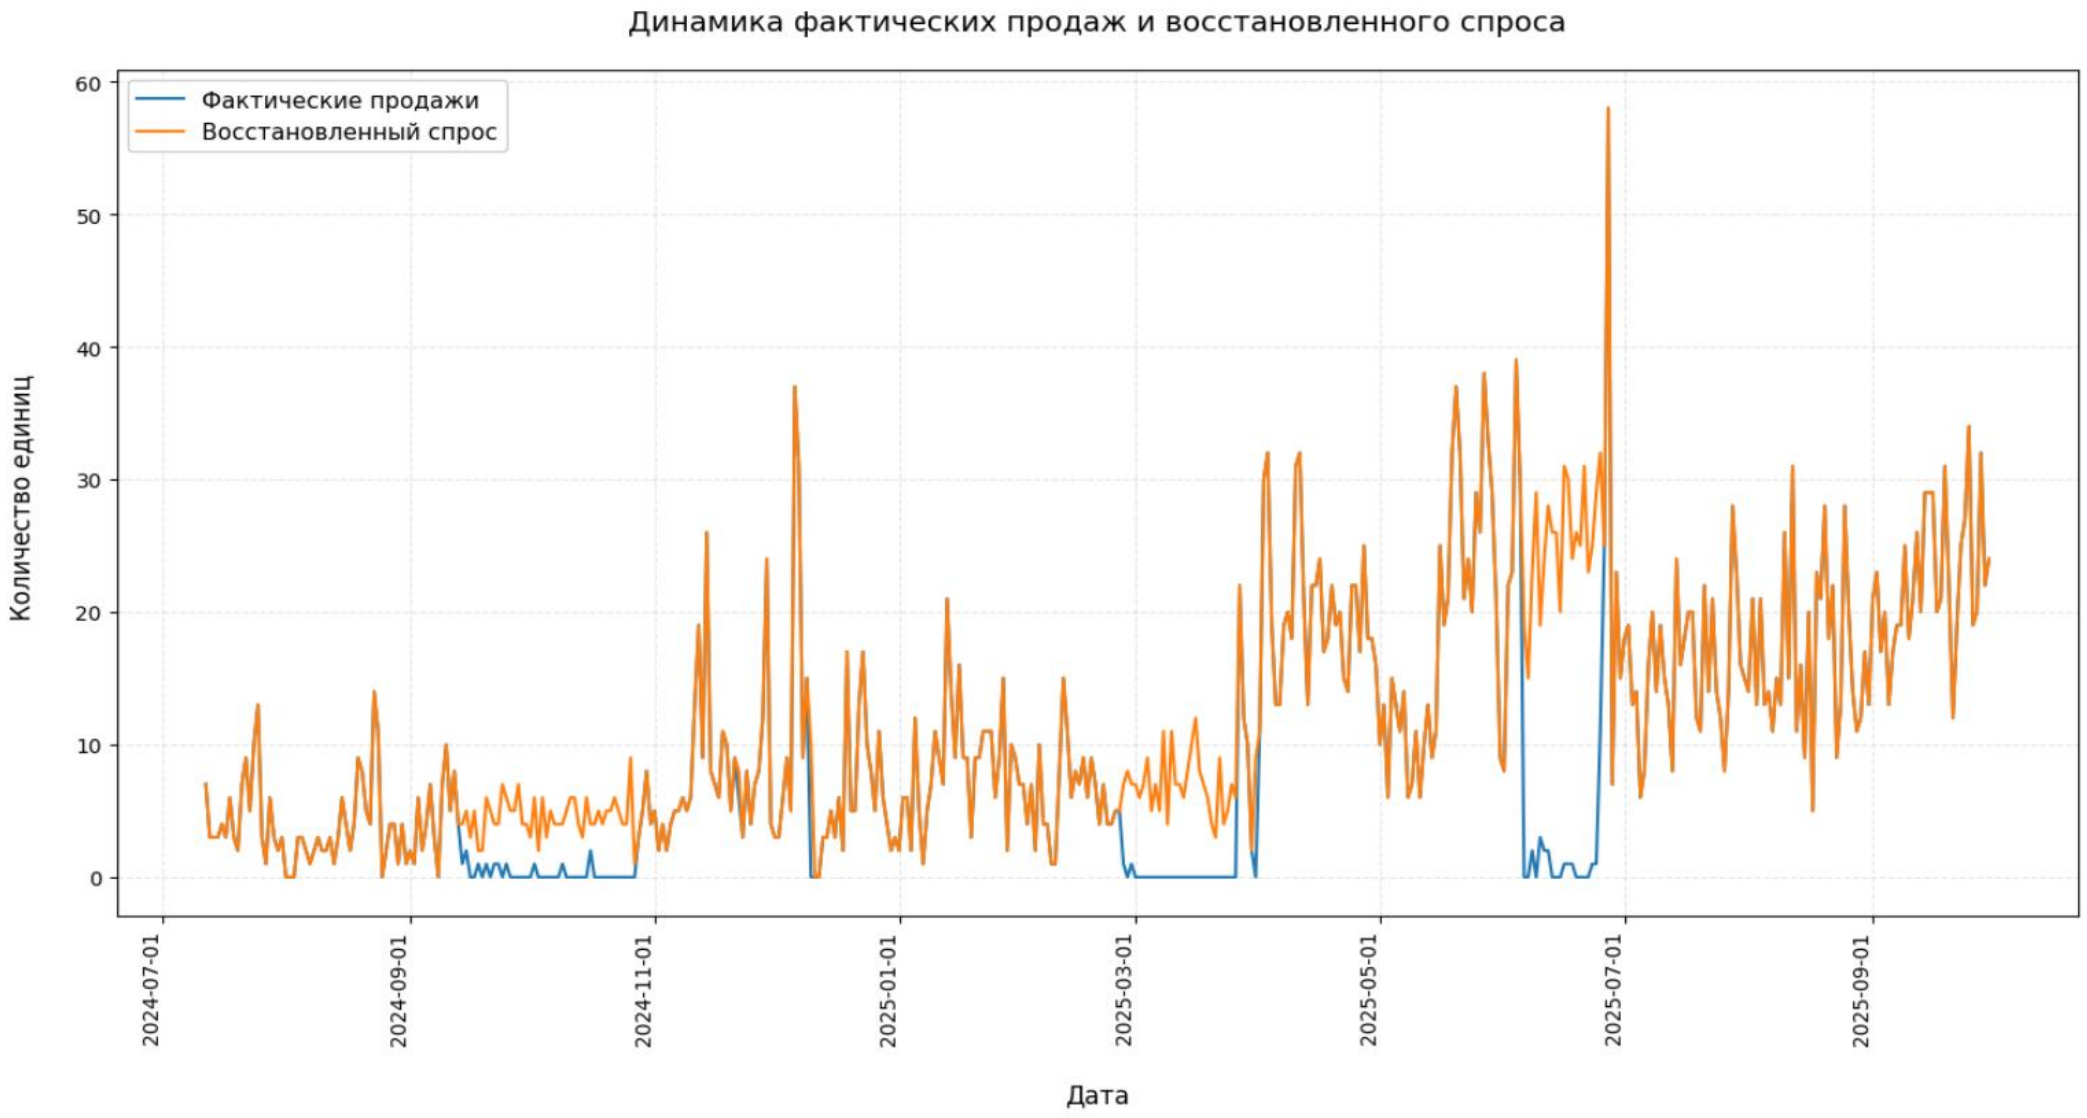
Динамика фактических продаж и восстановленного спроса
Фактические продажи
Восстановленный спрос
Количество единиц
0
10
20
30
40
50
60
2024-07-01
2024-09-01
2024-11-01
2025-01-01
2025-03-01
2025-05-01
2025-07-01
2025-09-01
Дата

Категоризация временных рядов

Проблема универсальных алгоритмов

– Данные интернет-торговли крайне неоднородны: высокая волатильность, разреженность, обилие нулевых продаж. Модели для стабильных продаж проваливаются на прерывистом спросе, и наоборот.

Решение – осмысленная категоризация

– Разбивка ассортимента на группы со схожими характеристиками для подбора адекватного аппарата (от статистических методов до нейросетей).

Выбранная методология – SBC

– Категоризация временного ряда на основе подхода SBC (Syntetos, Boylan, Croston, 2005) заключается в разделении временных рядов на типы в зависимости от двух факторов – ADI (характеризует частоту продаж) и CV2 (характеризует степень волатильности продаж).

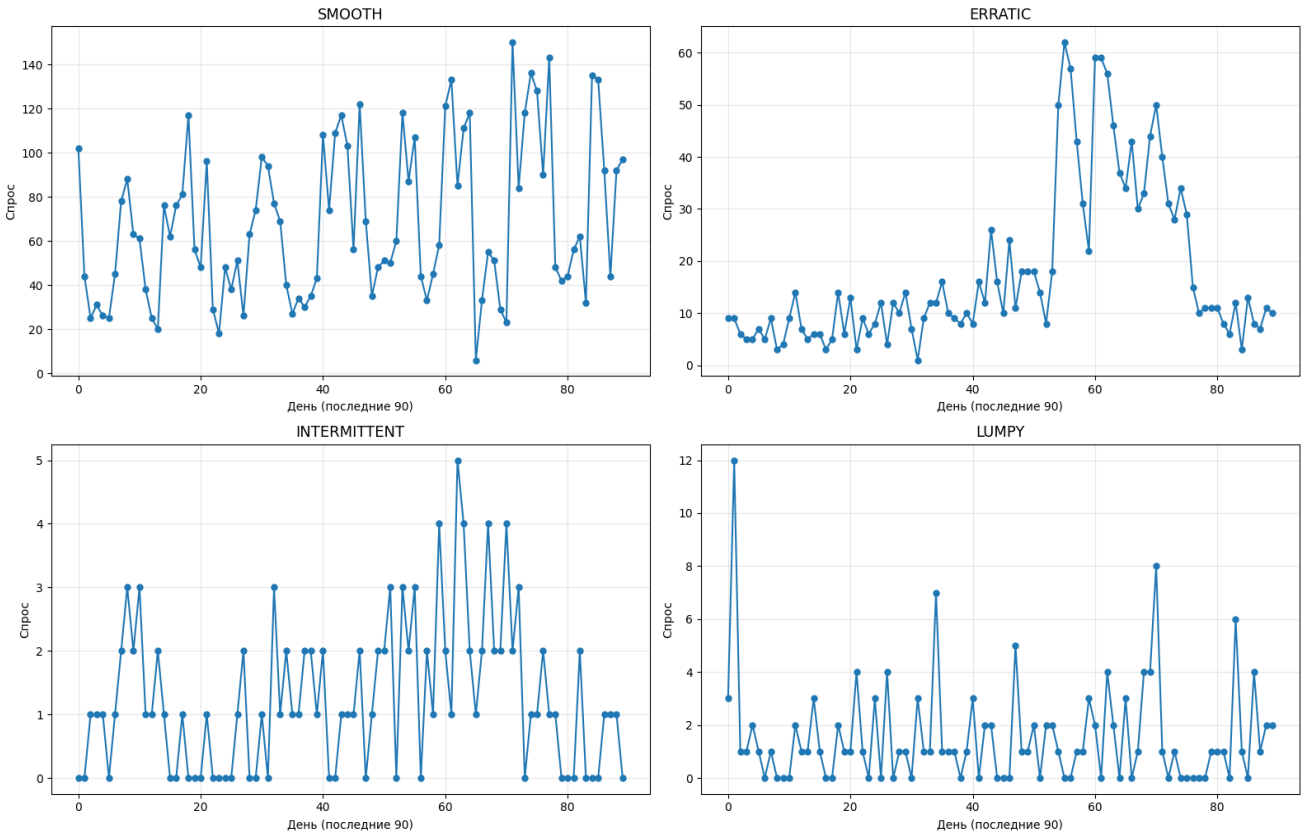

Визуализация категорий рядов по SBC на примерах SKU из датасета

Методология SBC

Классификация на основе SBC базируется на двух ключевых параметрах временного ряда:

- ADI (Average Demand Interval). Средний интервал между возникновениями спроса. Характеризует то, как часто возникает спрос.

$$\mathbf{ADI} = \frac{\sum_{i=1}^{n} t_i}{n}$$, где t_i – интервал между ненулевыми продажами, n – количество таких интервалов.

- CV^2 (Squared Coefficient of Variation). Квадрат коэффициента вариации объемов спроса. Характеризует степень изменчивости спроса.

$$\mathbf{CV^2} = \left(\frac{\sigma}{\mu}\right)^2$$, где σ – стандартное отклонение спроса за период, μ – среднее арифметическое спроса за период.

ADI / CV2	CV2 < 0.49	CV2 ≥ 0.49
ADI < 1.32	Smooth	Erratic
ADI ≥ 1.32	Intermittent	Lumpy

Тип ряда	Кол-во рядов	% от общего кол-ва рядов	% от общего оборота (шт)
Smooth	1808	12%	55%
Erratic	841	5%	20%
Intermittent	8355	54%	14%
Lumpy	3160	20%	10%
Retired	1307	8%	1%

Распределение временных рядов по категориям

Основные модели прогнозирования

В рамках исследования использовалось несколько групп моделей для прогнозирования:

– Простейшие базовые модели (бенчмарки)

Элементарные методы, которые не строят сложной структуры ряда – они либо повторяют последнее наблюдение, либо усредняют. Используются как минимальный порог качества: любая серьёзная модель должна быть лучше их.

– Модели временных рядов

Методы, основанные на математической статистике: ARIMA-семейство, декомпозиция. Они улавливают тренд, сезонность и автокорреляции, хорошо интерпретируются, некоторые могут работать с внешними регрессорами.

– Модели машинного обучения

Модели, способные автоматически извлекать нелинейные зависимости и взаимодействия между лагами, календарными признаками и внешними регрессорами. Обычно требуют ручной генерации признаков.

– Глубокие нейросети

Современные архитектуры, специально адаптированные к прогнозированию временных рядов. Они могут обучаться на сырых последовательностях, автоматически выявлять долгосрочные зависимости и работать с множеством временных рядов одновременно.

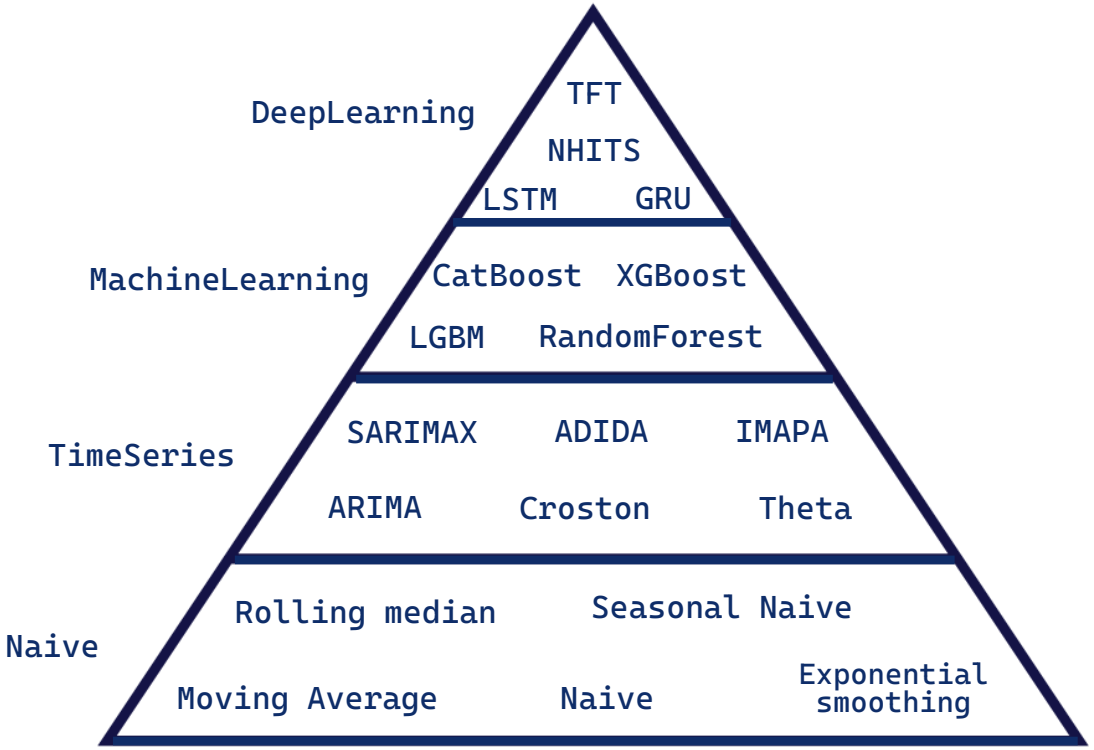

Пирамида развития моделей прогнозирования

Кросс-валидация

Горизонт прогнозирования составляет 14 дней. Все доступные исторические данные разделены на три непересекающиеся части:

- Обучающая выборка (Training). Это самый продолжительный период, на котором происходит обучение моделей и обновление весов.
- Валидационная выборка (Validation). Одно окно длиной 14 дней. Используется исключительно для подбора гиперпараметров, коэффициентов и прочих конфигураций моделей. Веса моделей не пересчитываются.
- Тестовая выборка (Forecasting). Три последовательных окна по 14 дней. На этих окнах рассчитываются финальные метрики качества уже финализированных моделей

Финальная метрика качества каждой модели рассчитывается по следующей формуле:

$$\text{Error} = \frac{1}{N \cdot J} \sum_{i=1}^{N} \sum_{j=1}^{J} \text{Error}_{i,j}$$

, где N – общее количество товаров; J – общее количество окон.

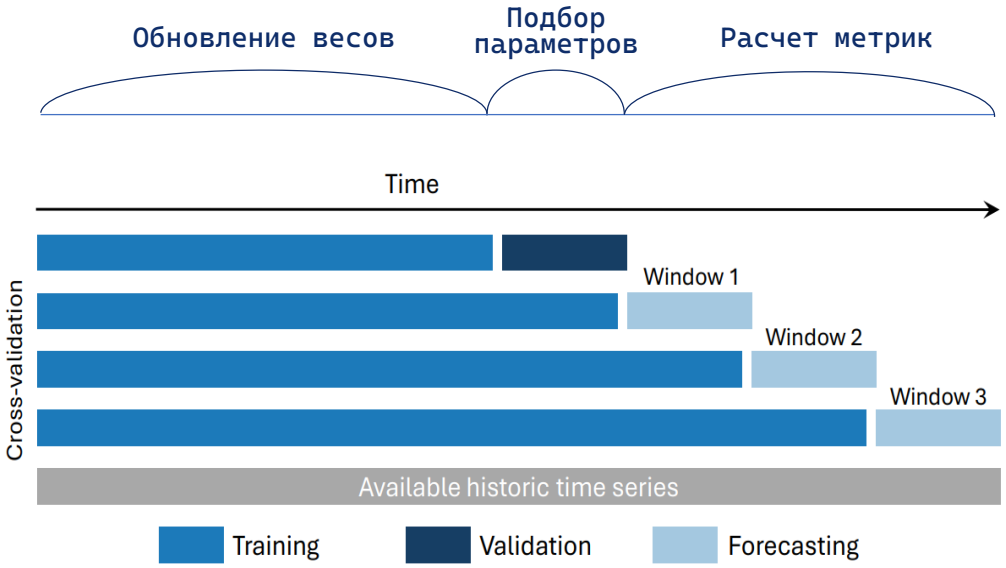

Training	01.01.2024 – 05.08.2025	
Validation	06.08.2025 – 19.08.2025	
Forecasting	20.08.2025 – 02.09.2025	(window 1)
Forecasting	03.09.2025 – 16.09.2025	(window 2)
Forecasting	17.09.2025 – 30.09.2025	(window 3)

Описание процесса валидации и прогнозирования

Метрики качества прогнозов

Для анализа и сравнения качества прогнозов различных моделей использовались следующие метрики:

- MAE – средняя абсолютная ошибка в единицах исходного ряда. Показывает абсолютный уровень отклонения без учёта знака. Чем меньше, тем точнее модель.
- RMSE – корень из средней квадратичной ошибки. Также в единицах ряда, но сильнее штрафует крупные промахи. Полезна, когда важнее бороться с выбросами.
- sMAPE – симметричная абсолютная процентная ошибка (0–200%). Даёт относительную точность, устойчива к делению на ноль и симметрична. Удобна для сравнения рядов с разными масштабами.
- WAPE – взвешенная абсолютная процентная ошибка. Отношение суммы абсолютных ошибок к сумме фактических значений. Отражает общую долю ошибки в суммарном объёме. Простая и интерпретируемая бизнес-метрика.
- MASE – средняя абсолютная масштабированная ошибка. Делит MAE модели на MAE простого наивного прогноза на обучающей выборке. Не зависит от масштаба данных и исключает проблемы деления на ноль.
- Bias – относительный показательный систематического завышения / занижения прогнозов. Значение >1 означает систематическое завышение прогнозов, <1 – занижение.

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

$$\mathrm{sMAPE} = \frac{100\%}{n}\sum_{i=1}^{n}\frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2}$$

$$\mathrm{WAPE} = \frac{\sum_{i=1}^{n}|y_i - \hat{y}_i|}{\sum_{i=1}^{n}|y_i|} \times 100$$

$$\mathrm{MASE} = \frac{\mathrm{MAE}_{\mathrm{model}}}{\mathrm{MAE}_{\mathrm{naive}}}$$

$$\mathrm{Bias} = \frac{\sum_{i=1}^{N}\hat{y}_i}{\sum_{i=1}^{N}y_i}$$

Smooth ряды

Основные выводы по метрикам:

- Все не-наивные модели значимо превосходят Naive. Среднее снижение ошибки по сравнению с Naive для топ-3 моделей составляет 18-20%.
- Топ-3 модели по большинству метрик – NHITS, AutoARIMA и ADIDA.
- NHITS абсолютный лидер по большинству метрик.
- Нейросети не имеют решающего преимущества. Более простые статистические модели показывают сопоставимые результаты.
- Если сравнивать NHITS с более сложными бенчмарками, например – AutoETS, то среднее улучшение метрик составляет 8%.
- Суммарная абсолютная ошибка наилучшей модели NHITS составляет около трети от общего объёма продаж – 36%.

Model	MAE	RMSE	sMAPE	WAPE	MASE	Bias
NHITS	4.494 (1)	9.114 (1)	54.522	36.137 (1)	1.098 (1)	0.907
AutoARIMA	4.645 (2)	9.431 (2)	53.210 (1)	37.380 (2)	1.122 (2)	1.015
ADIDA	4.712 (3)	9.726	53.349 (2)	37.931 (3)	1.125 (3)	1.018
IMAPA	4.714	9.728	53.381 (3)	37.948	1.126	1.019
GRU	4.727	10.007	55.960	38.013	1.127	0.927
LSTM	4.786	10.054	56.163	38.492	1.139	0.941
AutoARIMA_exog	4.795	9.608 (3)	57.794	38.575	1.161	0.952
HoltWinters	4.844	10.419	54.717	38.998	1.148	1.031
OptTheta	4.862	10.559	54.025	39.152	1.148	1.045
AutoETS	4.898	10.651	54.050	39.443	1.147	1.045
lgb_mae_base	4.959	11.537	56.982	39.882	1.152	0.884
Naive	5.597	11.213	65.045	45.073	1.397	1.050
SeasonalNaive7	5.805	11.843	66.690	46.744	1.412	1.023

Итоговые метрики качества для smooth рядов

Smooth ряды визуализация

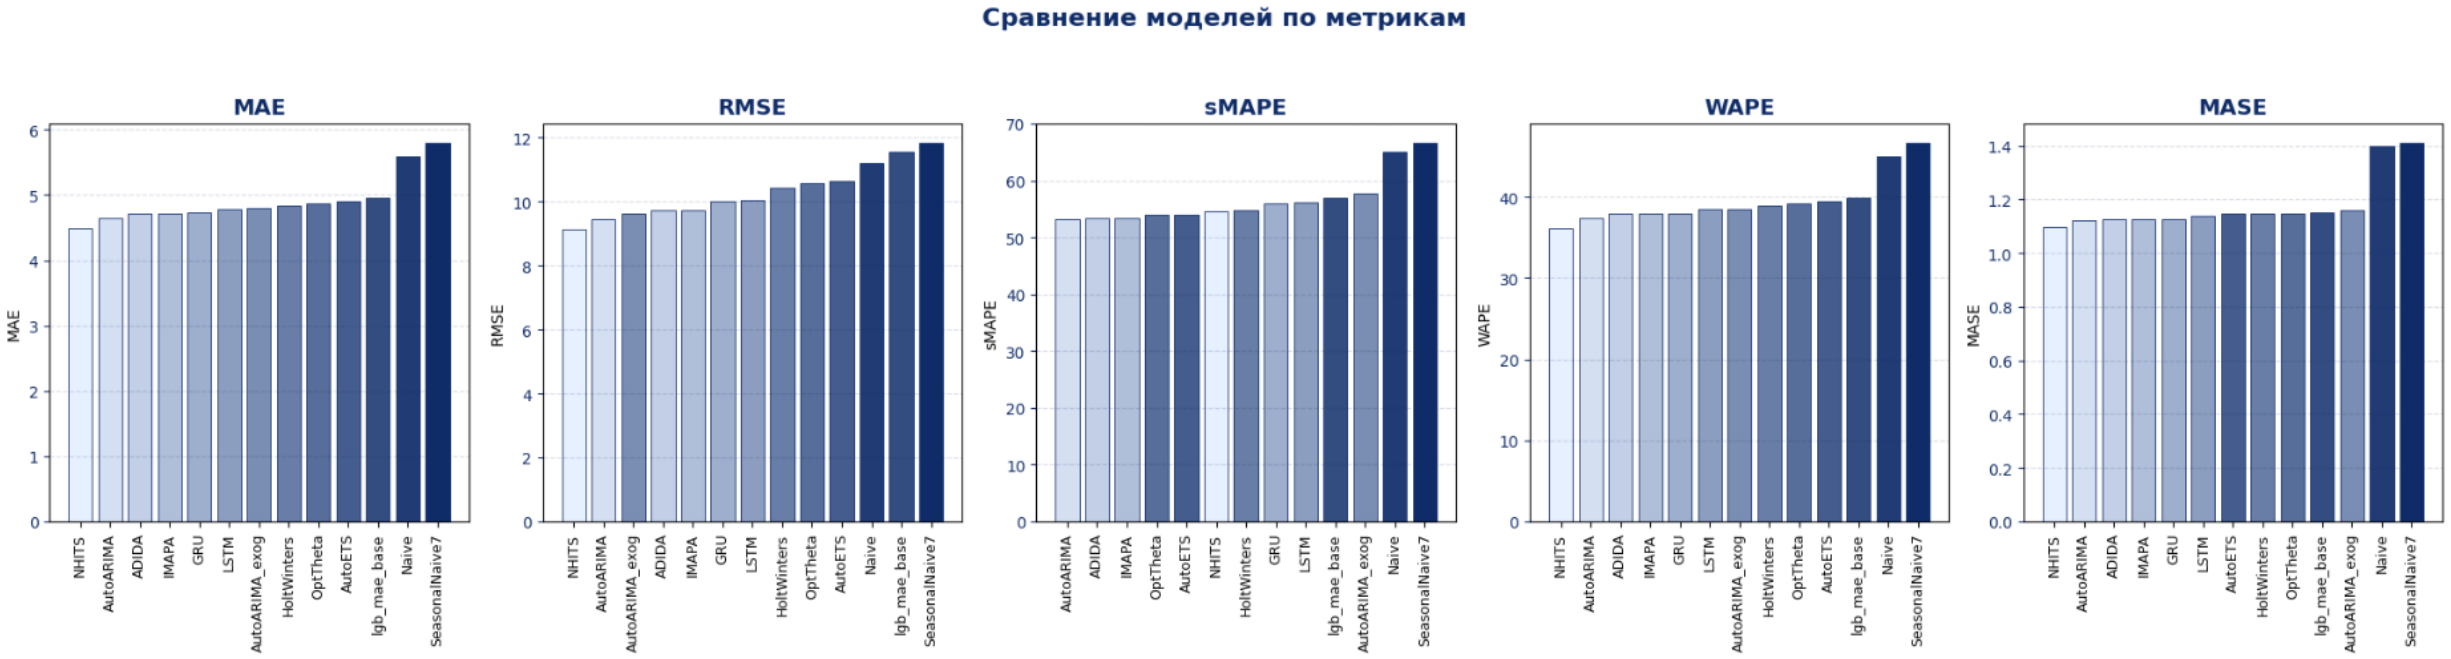

Erratic ряды

Основные выводы по метрикам:

- Все не-наивные модели значимо превосходят Naive. Среднее снижение ошибки по сравнению с Naive для топ-3 моделей составляет 16%.
- Топ-3 модели по большинству метрик – NHITS, LSTM и lgb.
- NHITS абсолютный лидер по большинству метрик.
- Экзогенные переменные играют куда большую роль для Erratic рядов.
- Если сравнивать NHITS с более сложными бенчмарками, например – AutoETS, то среднее улучшение метрик составляет 10%.
- Суммарная абсолютная ошибка наилучшей модели NHITS составляет около 64%.

Model	MAE	RMSE	sMAPE	WAPE	MASE	Bias
NHITS	5.662 (1)	26.383 (1)	78.879	64.387 (1)	1.356 (1)	0.822
lgb_mae_base	5.955 (2)	27.225	84.162	67.829 (3)	1.411 (2)	0.733
LSTM	5.961 (3)	26.613 (2)	84.109	67.819 (2)	1.412	0.796
GRU	5.989	26.629 (3)	82.828	68.142	1.411 (3)	0.826
ADIDA	6.283	27.068	78.683 (2)	71.526	1.466	0.985
IMAPA	6.287	27.079	78.807 (3)	71.564	1.468	0.985
AutoARIMA	6.373	27.608	78.516 (1)	72.641	1.483	1.018
AutoARIMA_exog	6.398	27.511	84.271	72.853	1.456	0.914
OptTheta	6.555	27.629	81.067	74.670	1.526	1.014
AutoETS	6.675	28.349	80.832	76.032	1.551	1.026
Naive	6.903	27.940	91.831	78.679	1.738	0.979
SeasonalNaive7	7.435	30.281	95.083	84.683	1.763	0.967

Итоговые метрики качества для erratic рядов

Erratic ряды визуализация

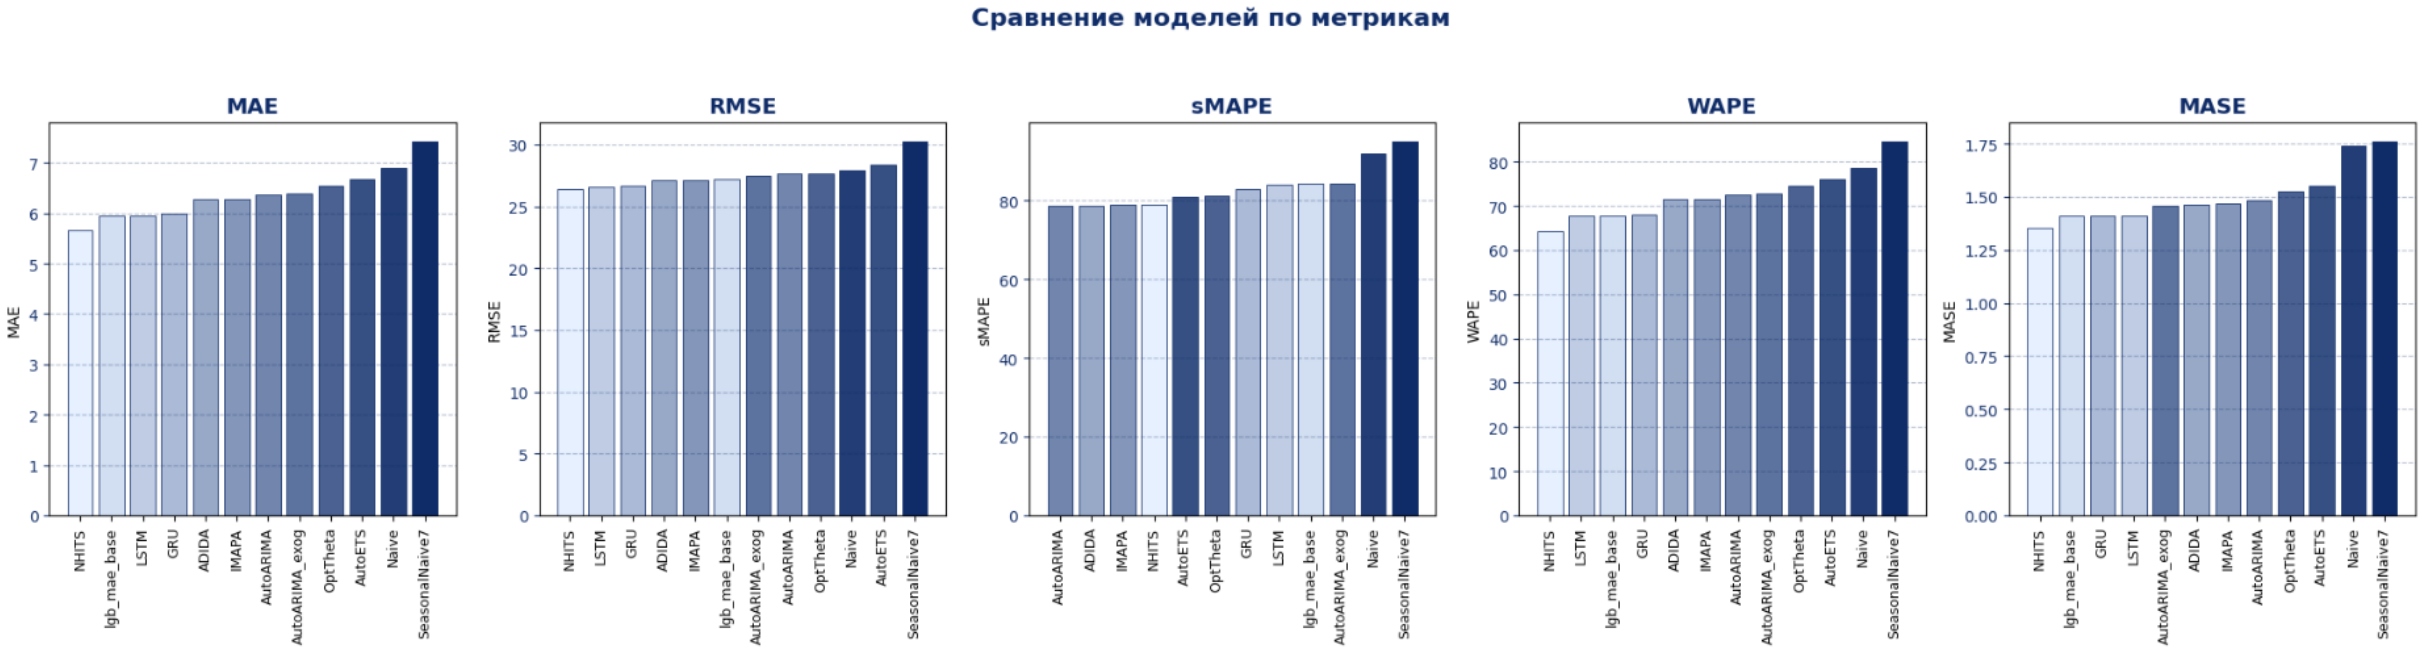

Intermittent ряды

Основные выводы по метрикам:

- ML и нейросетевые методы дают заниженные прогнозы. Эксперименты с преобразованием таргета и использование разных loss-функций не позволили значительно улучшить качество.
- MAE – становится менее информативной метрикой на рядах с большим количеством нулей.
- Наилучшие результаты демонстрируют модели, специализированные под прерывистый спрос – TSB, ADIDA и IMAPA.
- TSB, ADIDA и IMAPA в среднем лучше наивного прогноза на 12–16%.
- TSB, ADIDA и IMAPA в среднем лучше экспоненциального сглаживания на 2–4%.

Model	MAE	RMSE	sMAPE	WAPE	MASE	Bias
lgb_mae_base	0.310 (1)	0.877 (3)	169.287	80.329 (1)	0.725 (1)	0.471
LSTM	0.353 (2)	0.921	180.111	91.620 (2)	0.867 (3)	0.673
GRU	0.354 (3)	0.923	180.128	91.673 (3)	0.866 (2)	0.672
NHITS	0.370	0.957	191.661	95.873	0.871	0.271
AutoARIMA_exog	0.446	0.930	176.337	115.799	1.034	0.997
IMAPA	0.456	0.872 (2)	177.860	118.190	1.157	1.009
TSB_02_02	0.457	0.879	177.881	118.620	1.232	1.032
ADIDA	0.458	0.871 (1)	177.961	118.725	1.134	1.002
WindowAvg_7	0.460	0.904	165.688 (3)	119.279	1.246	1.031
AutoETS	0.468	0.901	177.987	121.486	1.366	1.044
OptTheta	0.475	0.901	178.038	123.315	1.285	1.017
Naive	0.512	1.140	158.687 (1)	132.957	1.380	1.059
SeasonalNaive7	0.514	1.146	160.264 (2)	133.324	1.335	1.031
CrostonSBA	0.515	0.902	177.374	133.471	1.445	1.123
CrostonOpt	0.515	0.904	176.884	133.561	1.426	1.176

Итоговые метрики качества для intermittent рядов

Intermittent ряды визуализация

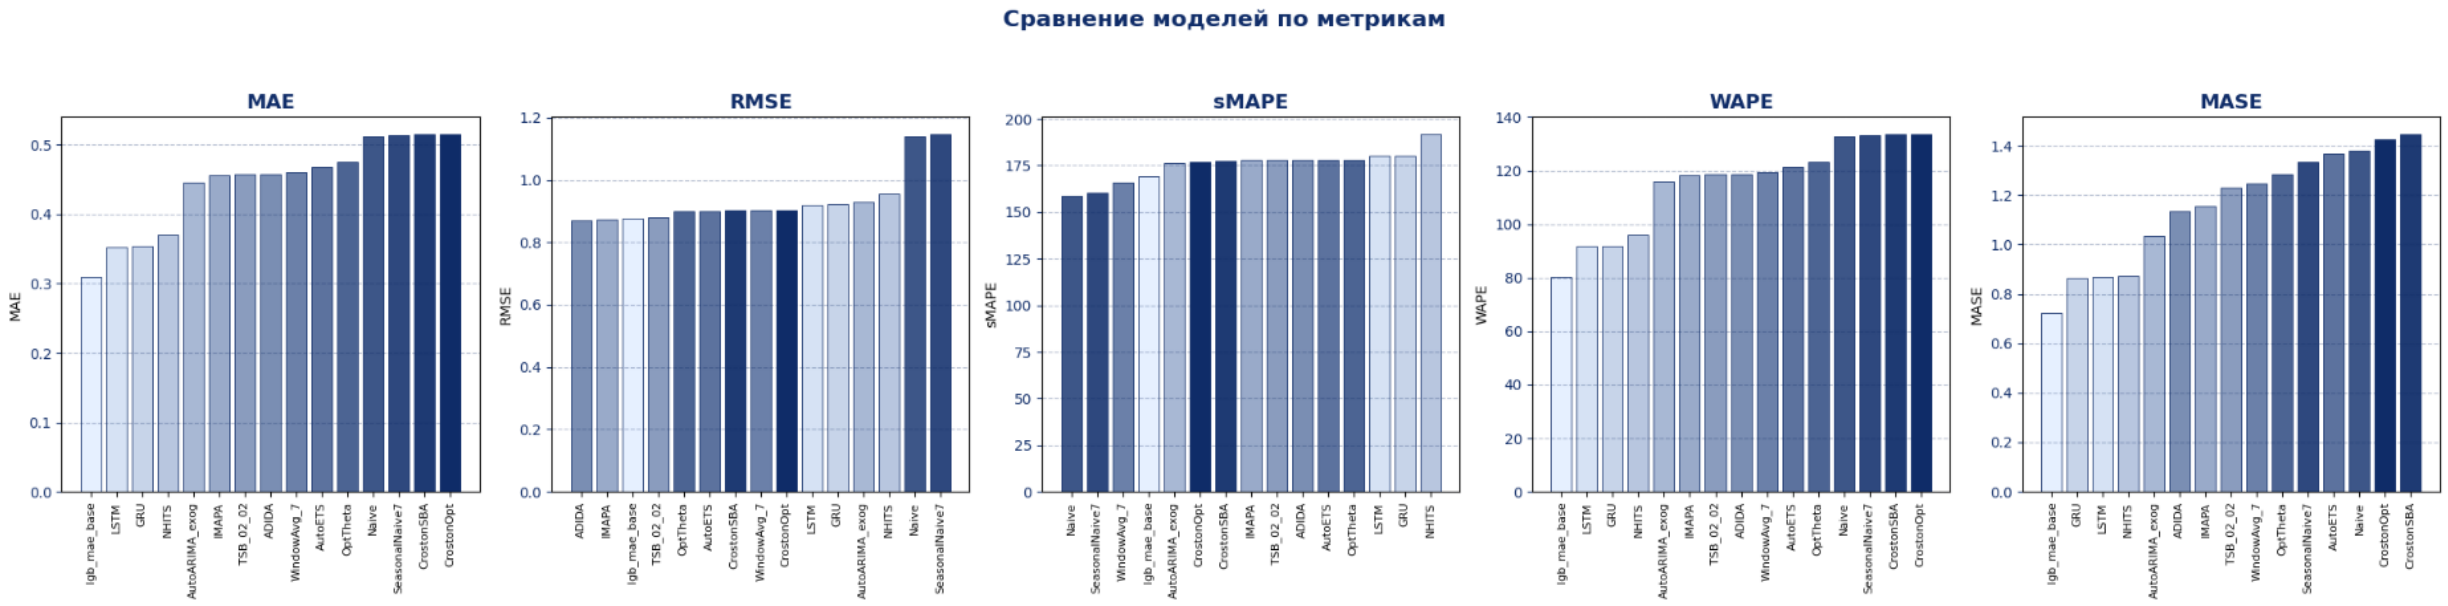

Lumpy ряды

Основные выводы по метрикам:

- ML и нейросетевые методы дают заниженные прогнозы. Эксперименты с преобразованием таргета и использование разных loss-функций не позволили значительно улучшить качество.
- MAE – становится менее информативной метрикой на рядах с большим количеством нулей.
- Наилучшие результаты демонстрируют модели, специализированные под прерывистый спрос – TSB, ADIDA и IMAPA.
- TSB, ADIDA и IMAPA в среднем лучше наивного прогноза на 12–17%.
- TSB, ADIDA и IMAPA в среднем лучше экспоненциального сглаживания на 4–8%.

Model	MAE	RMSE	sMAPE	WAPE	MASE	Bias
lgb_mae_base	0.936 (1)	2.637	164.603	84.718 (1)	1.371 (1)	0.455
GRU	1.018 (2)	2.719	161.742	92.097 (2)	1.468 (2)	0.612
LSTM	1.019 (3)	2.723	161.938	92.177 (3)	1.470 (3)	0.607
NHITS	1.023	2.690	174.510	92.586	1.508	0.362
IMAPA	1.211	2.629 (2)	154.193	109.585	1.785	0.973
ADIDA	1.211	2.630 (3)	154.013	109.594	1.765	0.958
TSB_015_015	1.212	2.612 (1)	153.249	109.719	1.810	0.985
AutoARIMA_exog	1.237	2.963	156.507	111.858	1.736	0.902
WindowAvg_7	1.245	2.721	147.851 (2)	112.670	1.870	0.989
AutoETS	1.266	2.806	155.630	114.581	1.947	1.033
OptTheta	1.270	2.774	156.125	114.909	1.900	1.011
CrostonSBA	1.281	2.703	152.239	115.921	1.841	0.991
CrostonOpt	1.297	2.742	152.072	117.390	1.882	1.060
Naive	1.378	3.164	146.599 (1)	124.712	2.086	1.021
SeasonalNaive7	1.411	3.306	148.641 (3)	127.690	2.048	0.989

Итоговые метрики качества для lumpy рядов

Lumpy ряды визуализация

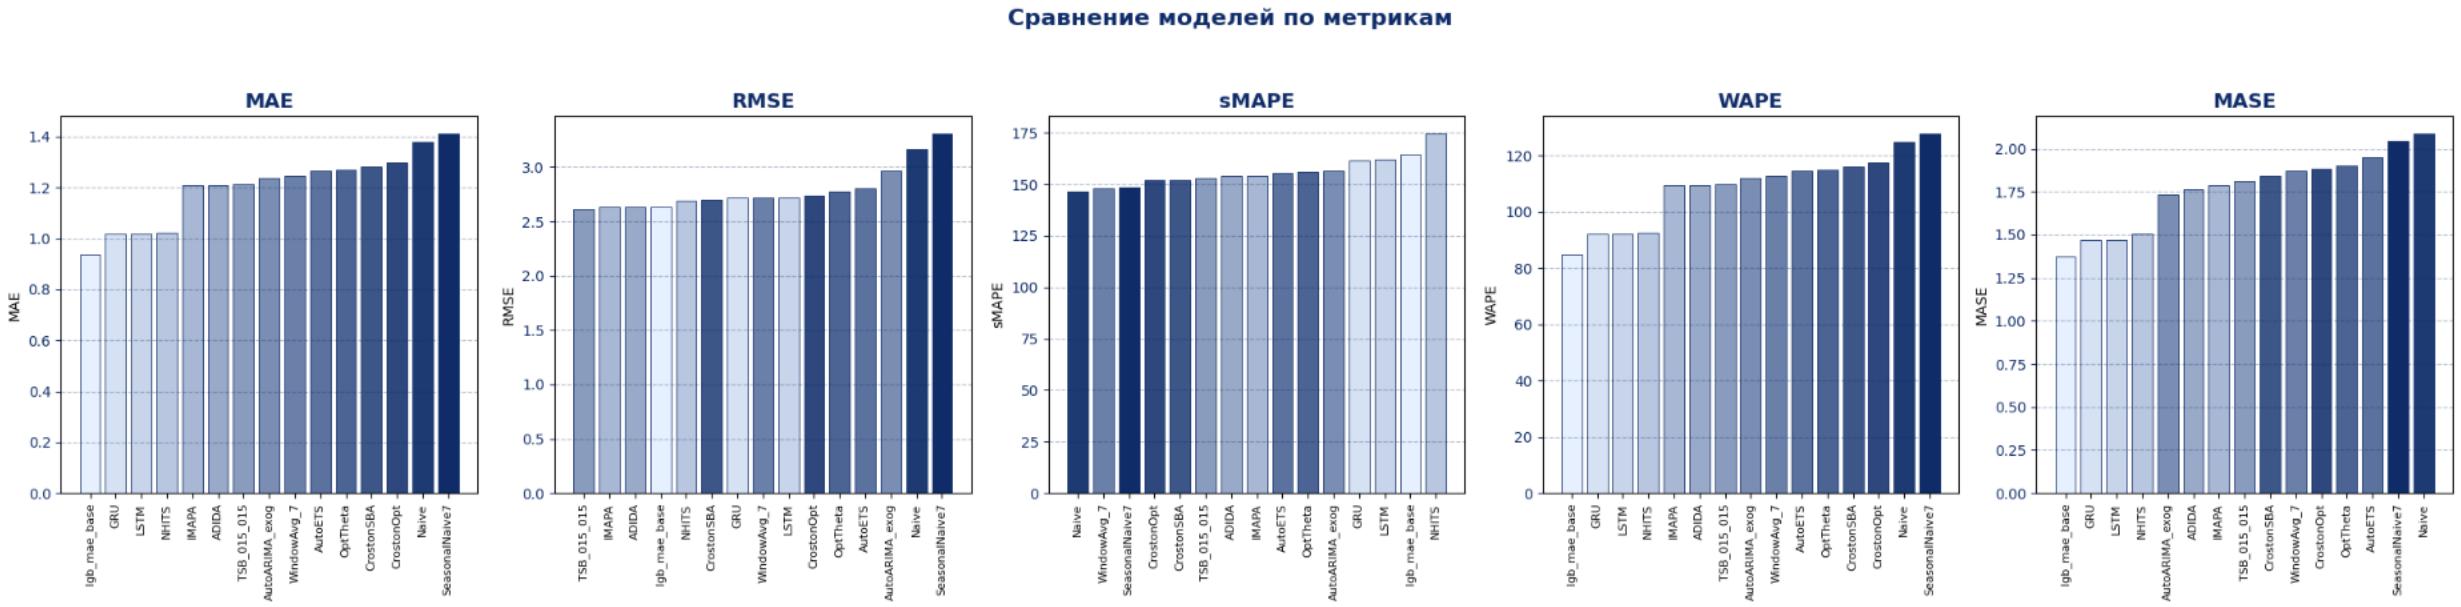

Итоги

1. Данные были подготовлены, очищены и проанализированы. Мы провели глубокий разведочный анализ, выявили пропуски, аномалии и скрытые взаимосвязи.
2. Был разработан и реализован алгоритм по восстановлению спроса на рассматриваемые товары. Алгоритм учитывал периоды дефицита, восстанавливая реальную картину потребностей покупателей. Это позволило отделить истинный спрос от искажённых исторических данных и значительно повысить информативность обучающей выборки.
3. Была проведена сегментация временных рядов на основе характера продаж различных товаров. Мы сгруппировали товары по частоте продаж и волатильности, выделив устойчивые кластеры. Такой подход дал возможность настраивать модели под поведенческие паттерны каждой группы, а не использовать усреднённое решение для всего ассортимента.
4. Для каждого временного ряда был протестирован широкий спектр моделей. Разработанные модели позволили уменьшить ошибку прогноза на 10–20%. Сравнивались классические статистические методы, алгоритмы машинного обучения и архитектуры глубокого обучения. Внедрение данных моделей позволит значительно повлиять на финансовые результаты компании.

ВЫСШАЯ • ШКОЛА • ЭКОНОМИКИ •